

Aufgabenbeschreibung

</> Code ▼

Datenbeschreibung

Das Land Berlin veröffentlicht jährlich detaillierte Informationen zu staatlichen Zuwendungen. Der Datensatz sowie die Datendefinitionen sind über die Zuwendungsdatenbank verfügbar:

- <https://www.berlin.de/sen/finanzen/service/zuwendungsdatenbank/>

Klassifizierungsaufgabe

Ziel ist die Entwicklung eines Klassifikators, der anhand der verfügbaren Merkmale den jeweiligen `politikbereich` vorhersagen kann.

Rahmenbedingungen

Die Lösung soll in einer vergleichbaren Arbeitsumgebung entwickelt werden. Empfohlene Werkzeuge und Anforderungen sind:

- Pandas, nltk, scikit-learn, keras und matplotlib,
- Jupyter Notebooks als Abgabeformat,
- Auswertung und Visualisierung der Ergebnisse,
- kurze Präsentation der Ergebnisse für Fachexperten und Vorstand.

Dafür werden alle notwendigen Schritte von der Datenprüfung über die Vorverarbeitung bis zur Modellvorbereitung nachvollziehbar dokumentiert.

0. Problemdefinition

0.1. Allgemein

Zielspalte: `politikbereich`

Problemtyp: Single-Label-Mehrklassenklassifikation

Jeder Datensatz soll genau einem Politikbereich zugeordnet werden. Die Klassifikation basiert auf textuellen, kategorialen und numerischen Merkmalen. Da die Zielvariable deutlich unausgewogen ist, müssen Modellauswahl und Evaluation besonders sorgfältig erfolgen.

0.2 Definition der Evaluationsmetriken

Bei der vorliegenden Aufgabe handelt es sich um ein **Mehrklassen-Klassifikationsproblem**, bei dem Texte einem bestimmten Politikbereich zugeordnet werden. Da die Klassen im Datensatz unterschiedlich häufig vertreten sind, reicht eine einzelne Kennzahl wie die Accuracy nicht aus.

Insbesondere große Klassen könnten die Gesamtbewertung dominieren, während eine schlechte Erkennungsleistung bei kleineren Klassen unbemerkt bliebe. Deshalb werden mehrere, sich ergänzende Evaluationsmetriken verwendet.

0.2.1. Erklärung der Evaluationsmetriken

TP, TN, FP und FN

Die Vorhersagen eines Modells werden in vier Fälle unterteilt:

Abkürzung	Tatsächlicher Wert	Vorhersage	Bedeutung
TP	Positiv	Positiv	Etwas Positives wird richtig als positiv erkannt.
TN	Negativ	Negativ	Etwas Negatives wird richtig als negativ erkannt.
FP	Negativ	Positiv	Etwas Negatives wird fälschlicherweise als positiv erkannt.
FN	Positiv	Negativ	Etwas Positives wird fälschlicherweise als negativ erkannt.

- **True:** Die Vorhersage ist richtig.
- **False:** Die Vorhersage ist falsch.
- **Positive:** Das Modell sagt „Ja“.
- **Negative:** Das Modell sagt „Nein“.

Precision, Recall und F1-Score

Neben den aggregierten Kennzahlen werden Precision, Recall und F1-Score für jeden Politikbereich einzeln ausgewertet.

Precision

Die Precision beantwortet die Frage:

Wenn das Modell einen bestimmten Politikbereich vorhersagt, wie häufig ist diese Vorhersage korrekt?

$$\text{Precision} = \frac{TP}{TP + FP}$$

Eine niedrige Precision bedeutet, dass viele Dokumente fälschlicherweise dieser Klasse zugeordnet werden.

Recall

Der Recall beantwortet die Frage:

Wie viele der tatsächlich zu einem bestimmten Politikbereich gehörenden Dokumente werden vom Modell erkannt?

$$\text{Recall} = \frac{TP}{TP + FN}$$

Ein niedriger Recall bedeutet, dass viele Fälle einer Klasse übersehen und stattdessen anderen Politikbereichen zugeordnet werden.

F1-Score

Der F1-Score fasst Precision und Recall zu einer gemeinsamen Kennzahl zusammen. Die klassenweise Auswertung ist notwendig, weil ein globaler Mittelwert nicht erkennen lässt, welche konkreten Politikbereiche problematisch sind.

Sie ermöglicht eine gezielte Fehleranalyse und zeigt, für welche Klassen beispielsweise folgende Maßnahmen erforderlich sein könnten:

- zusätzliche Trainingsdaten,
- eine präzisere Klassendefinition,
- eine bessere Repräsentation der Texte,
- eine Überprüfung der Annotationen.

0.2.2 Evaluationsmetriken

Da die Zielvariable „politikbereich“ eine deutliche Klassenunverteilung aufweist, ist die reine Accuracy als Evaluationsmetrik nur eingeschränkt geeignet. Große Klassen wie „Wirtschaft“, „Arbeit“, „Sport“ oder „Jugend“ dominieren die Datenbasis, während einzelne Klassen wie „Berlin-Image“, „Tierschutz“, „Finanzen“, „Medien“ oder „Internationales“ nur sehr wenige Beobachtungen enthalten. Ein Modell könnte daher eine hohe Accuracy erreichen, indem es vor allem die häufigen Klassen gut vorhersagt, während die seltenen Klassen kaum korrekt erkannt werden.

Auch in der Literatur wird dieses Problem für unausgewogene Klassifikationsaufgaben beschrieben. He und Garcia (2009) zeigen in ihrem Überblick zu Imbalanced Learning, dass klassische Lernverfahren bei stark unterrepräsentierten Klassen häufig schlechtere Ergebnisse erzielen und dass Standardmetriken wie Accuracy die tatsächliche Modellleistung verzerren können. Deshalb werden für diese Arbeit zusätzlich klassenbezogene Metriken verwendet.

Für die Bewertung des Modells werden daher neben der Accuracy insbesondere Precision, Recall und F1-Score betrachtet. Dabei ist der Macro-F1-Score besonders wichtig, weil er jede Klasse unabhängig von ihrer Häufigkeit gleich stark gewichtet. Der Weighted-F1-Score ergänzt diese Sicht, da er die tatsächliche Klassenverteilung berücksichtigt. Zusätzlich werden die Ergebnisse pro Klasse ausgewiesen, damit sichtbar bleibt, ob das Modell nur die großen Klassen gut erkennt oder auch bei kleineren Politikbereichen brauchbare Vorhersagen liefert.

Klassen mit sehr geringer Fallzahl werden nicht automatisch entfernt oder größeren Klassen zugeordnet. Stattdessen werden sie in der Evaluation als Klassen mit geringer statistischer Belastbarkeit betrachtet. Dadurch bleibt die ursprüngliche Zielstruktur erhalten, gleichzeitig werden die Kennzahlen für seltene Klassen vorsichtig interpretiert.

Quelle: He, H. und Garcia, E. A. (2009): Learning from Imbalanced Data. IEEE Transactions on Knowledge and Data Engineering. <https://ieeexplore.ieee.org/document/5128907>

Hauptmetrik: Macro-F1

Der **Macro-F1-Score** berechnet den F1-Score für jede Klasse und bildet daraus den Durchschnitt. Dabei zählt jede Klasse gleich viel – unabhängig davon, wie häufig sie vorkommt.

Diese Metrik ist besonders wichtig, weil sie zeigt, ob das Modell sowohl häufige als auch seltene Politikbereiche zuverlässig erkennt.

Weitere Metriken

- **Weighted-F1:** Berücksichtigt die Häufigkeit der Klassen. Häufige Klassen haben dadurch einen größeren Einfluss.
- **Balanced Accuracy:** Berechnet die durchschnittliche Erkennungsrate aller Klassen. Jede Klasse wird gleich gewichtet.
- **Accuracy:** Zeigt den Anteil aller richtigen Vorhersagen. Bei ungleich verteilten Klassen kann dieser Wert jedoch irreführend sein.
- **Precision, Recall und F1 pro Klasse:** Zeigen, bei welchen Politikbereichen das Modell gut oder schlecht funktioniert.

Konfusionsmatrix

Die **Konfusionsmatrix** zeigt, welche Klassen korrekt erkannt und welche miteinander verwechselt werden.

- **Zeilen:** tatsächliche Klassen
- **Spalten:** vorhergesagte Klassen
- **Diagonale:** korrekte Vorhersagen
- **Andere Felder:** Fehlklassifikationen

Übersicht

Metrik	Zweck
Macro-F1	Gleichwertige Bewertung aller Klassen

Metrik	Zweck
Weighted-F1	Bewertung entsprechend der Klassenhäufigkeit
Balanced Accuracy	Durchschnittliche Erkennungsrate aller Klassen
Accuracy	Anteil aller korrekten Vorhersagen
Metriken pro Klasse	Erkennung problematischer Klassen
Konfusionsmatrix	Darstellung typischer Verwechslungen

Der **Macro-F1-Score** wird als Hauptmetrik verwendet, da er bei einer ungleichen Klassenverteilung eine faire Gesamtbewertung ermöglicht.

0.3. DataFrame vorbereiten

Der ursprüngliche DataFrame wird kopiert, damit die explorative Analyse und die spätere Vorverarbeitung nachvollziehbar durchgeführt werden können, ohne die Rohdaten zu verändern.

► Code

	id	name	geber	art	jahr	anschrift	politikbereich	zweck	betra
0	1	"AUSLÄNDER MIT UNS" - Verein zur Förderung int...	Bezirksamt Tempelhof- Schöneberg	Projektförderung	2022	Geßlerstraße 11, 10829 Berlin	Integration	Vernetzung und Information aller Migrant_innen...	1724
1	4	» mehrSicht « jugend*kultur*bildung e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2024	Pirolstraße 82, 12683 Berlin	Wirtschaft	Solidarisches Handeln? Welthandel erkunden f...	4000
2	7	e. V.SV Preußen Berlin e. V.	Senatsverwaltung für Inneres und Sport	Projektförderung	2021	Hansastraße 190, 13088 Berlin	Sport	Kosten für die Beschäftigung von hauptberuflic...	4070
3	10	ITS Training Gesellschaft mit beschränkter Haf...	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2021	Am Oder- Spree-Kanal 23D, 12527 Berlin	Wirtschaft	Digitalprämie Berlin	4066
4	13	it's.BB e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2024	Poßweg 45, 14163 Berlin	Wirtschaft	Etablierung einer regionalen IT-/Cybersecurit...	46489

1. EDA (Explorative Data Analysis) vor Datenvorbereitung

Eine hohe Datenqualität bildet die Grundlage für leistungsfähige und zuverlässige Modelle. Fehlerhafte, unvollständige oder ungeeignete Daten können die Modellleistung beeinträchtigen und zu unzuverlässigen Vorhersagen führen. Daher werden die vorliegenden Daten zunächst sorgfältig untersucht und bei Bedarf bereinigt (vgl. Mohammed et al., 2025).

Unter qualitativ hochwertigen Daten werden in dieser Arbeit Daten verstanden, die korrekt, vollständig, konsistent und für die Klassifikationsaufgabe relevant sind. Darüber hinaus sollten die verschiedenen Politikbereiche ausreichend repräsentiert und die Dokumente möglichst korrekt annotiert sein. Duplikate, fehlerhafte Werte, uneinheitliche Schreibweisen und Datenlecks sollten vermieden werden.

Literatur

Mohammed, S., Budach, L., Feuerpfeil, M., Ihde, N., Nathansen, A., Noack, N., Patzlaff, H., Naumann, F. & Harmouch, H. (2025). *The Effects of Data Quality on Machine Learning Performance on Tabular Data*. Information Systems, 132, 102549. <https://doi.org/10.1016/j.is.2025.102549>

1.1. Allgemeine Untersuchung der Datenstruktur

1.1.1. Datenstruktur und -qualität

► Code

	id	name	geber	art	jahr	anschrift	politikbereich	zweck	betra
0	1	"AUSLÄNDER MIT UNS" - Verein zur Förderung int...	Bezirksamt Tempelhof-Schöneberg	Projektförderung	2022	Geßlerstraße 11, 10829 Berlin	Integration	Vernetzung und Information aller Migrant_innen...	1724
1	4	» mehrSicht « jugend*kultur*bildung e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2024	Pirolstraße 82, 12683 Berlin	Wirtschaft	Solidarisches Handeln? Welthandel erkunden f...	4000
2	7	e. V.SV Preußen Berlin e. V.	Senatsverwaltung für Inneres und Sport	Projektförderung	2021	Hansastraße 190, 13088 Berlin	Sport	Kosten für die Beschäftigung von hauptberuflic...	4070
3	10	ITS Training Gesellschaft mit beschränkter Haf...	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2021	Am Oder-Spree-Kanal 23D, 12527 Berlin	Wirtschaft	Digitalprämie Berlin	4066
4	13	it's.BB e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2024	Poßweg 45, 14163 Berlin	Wirtschaft	Etabilierung einer regionalen IT-/Cybersecurit...	46489

◀

▶

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 57469 entries, 0 to 57468
Data columns (total 10 columns):
#   Column          Non-Null Count  Dtype
#   ...
```

```

-----
0  id          57469 non-null int64
1  name        57469 non-null object
2  geber       57469 non-null object
3  art         57469 non-null object
4  jahr        57469 non-null int64
5  anschrift   57469 non-null object
6  politikbereich 57469 non-null object
7  zweck       57468 non-null object
8  betrag      57469 non-null int64
9  empfaengerid 55987 non-null object

```

dtypes: int64(3), object(7)

memory usage: 4.4+ MB

1.1.2. Datenqualität

► Code

Fehlende Werte:

	Anzahl
id	0
name	0
geber	0
art	0
jahr	0
anschrift	0
politikbereich	0
zweck	1
betrag	0
empfaengerid	1482

Eindeutige Werte:

	Anzahl
id	57469
name	13393
geber	43
art	3
jahr	5
anschrift	12125
politikbereich	34

	Anzahl
zweck	26875
betrag	28630
empfaengerid	10685

Anzahl der doppelten Zeilen: 0

id	name	geber	art	jahr	anschrift	politikbereich	zweck	betrag	empfaengerid
----	------	-------	-----	------	-----------	----------------	-------	--------	--------------

Ergebnis

Der Datensatz besteht aus **57.469 Zeilen** und **10 Spalten**. Es wurden keine vollständig doppelten Zeilen gefunden.

Bei den fehlenden Werten fallen insbesondere zwei Spalten auf:

- zweck: 1 fehlender Wert,
- empfaengerid: 1.482 fehlende Werte.

Die fehlenden Empfänger-IDs sind für die spätere Datenbereinigung besonders relevant, da sie als wichtiges Organisationsmerkmal verwendet werden können.

1.1.3. Untersuchung auf Auffälligkeiten in numerischen Spalten

Ungültige Jahresangaben

Die Spalte **jahr** wird auf fehlende, nicht numerische und unrealistische Jahresangaben überprüft.

► Code

Aktuelles Jahr: 2026

Anzahl ungültiger Jahresangaben: 0

Untersuchung der Beträge

Da in diesem Datensatz auch berechtigterweise sehr hohe Förderbeträge vorkommen können, werden hohe Werte nicht automatisch als Ausreißer betrachtet. Stattdessen werden Minimum, Maximum, Durchschnitt und Median untersucht.

► Code

	Kennzahl	Betrag in Euro
0	Minimum	100,00 €
1	Maximum	114.826.400,00 €
2	Durchschnitt	236.660,67 €
3	Median	29.500,00 €

Ergebnis


Die Beträge weisen eine stark unterschiedliche Höhe auf. Einzelne sehr hohe Förderbeträge erhöhen den Durchschnitt deutlich, während der Median robuster gegenüber diesen Extremwerten ist. Daher wird die Verteilung der Beträge später zusätzlich transformiert, bevor sie als numerisches Merkmal in der Modellierung verwendet wird.

1.2. Untersuchung der Klassenspalte “Politikbereich”

► Code

```
'Anyahl der Klassen: 34'
```

```
<Figure size 1000x1000 with 0 Axes>
```



► Code

	id	name	geber	art	jahr	anschrift	politikbereich
32835	98506	Landesfreiwilligenagentur Berlin e. V.	Regierende Bürgermeisterin/Regierender Bürgerm...	Projektförderung	2023	Schumannstraße 3, 10177 Berlin	Bürgerschaftli Engagement
32836	98509	Landesfreiwilligenagentur Berlin e. V.	Regierende Bürgermeisterin/Regierender Bürgerm...	Projektförderung	2023	Schumannstraße 3, 10177 Berlin	Bürgerschaftli Engagement



	id	name	geber	art	jahr	anschrift	politikbereich	zweck	betrag	ei
63	190	„Verschiedene Gesellschaften bürgerlichen Rechts	Bezirksamt Friedrichshain- Kreuzberg	Projektförderung	2023	'---'	Bürgerschaftliches Engagement, Bürgerbeteiligung	Bemalung Wandfläche Galilei- Grundschule, 17_20...	44662	N
64	193	„Verschiedene Gesellschaften bürgerlichen Rechts	Bezirksamt Friedrichshain- Kreuzberg	Projektförderung	2023	'---'	Bürgerschaftliches Engagement, Bürgerbeteiligung	Die Klinik der kaputten Dinge - das soziale Re...	34540	N
65	196	„Verschiedene Gesellschaften bürgerlichen Rechts	Bezirksamt Friedrichshain- Kreuzberg	Projektförderung	2023	'---'	Bürgerschaftliches Engagement, Bürgerbeteiligung	Förderung der Kiezidentität II, 17_2022000049_F	35000	N
66	199	„Verschiedene Gesellschaften bürgerlichen Rechts	Bezirksamt Friedrichshain- Kreuzberg	Projektförderung	2023	'---'	Bürgerschaftliches Engagement, Bürgerbeteiligung	Förderung der Kiezidentität, 12_2019011246	50000	N
219	658	1. Miniaturgolf- Verein Spandau e. V.	Bezirksamt Spandau	Projektförderung	2021	Fehrbelliner Straße 14, 13585 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	Instandsetzung Dach, Sanierung Bahnen, Umbau Z...	3500	vr



► Code

	id	name	geber	art	jahr	anschrift	politikbereich	zweck
32834	98503	Landesfreiwilligenagentur Berlin e. V.	Regierende Bürgermeisterin - Senatskanzlei -	Projektförderung	2022	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	13. B Stiftu Berli
32837	98512	Landesfreiwilligenagentur Berlin e. V.	Regierender Bürgermeister - Senatskanzlei -	Projektförderung	2020	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	11. B Stiftu Berli
32838	98515	Landesfreiwilligenagentur Berlin e. V.	Regierender Bürgermeister - Senatskanzlei -	Projektförderung	2021	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	12. B Stiftu Berli

	id	name	geber	art	jahr	anschrift	politikbereich	zweck
32855	98566	Landesfreiwilligenagentur Berlin e. V.	Senatsverwaltung für Kultur und Gesellschaftli...	Projektförderung	2024	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	Bera...
32856	98569	Landesfreiwilligenagentur Berlin e. V.	Senatsverwaltung für Kultur und Gesellschaftli...	Projektförderung	2024	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	Berli...
32857	98572	Landesfreiwilligenagentur Berlin e. V.	Senatsverwaltung für Kultur und Gesellschaftli...	Projektförderung	2024	Schumannstraße 3, 10117 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	Koor...

► Code

	id	name	geber	art	jahr	anschrift	politikbereich	zweck
6464	19393	Berliner Ringtheater e. V.	Senatsverwaltung für Kultur und Europa	Projektförderung	2021	Laskerstraße 5, 10245 Berlin	kultur	Einbau, Anmietung und Betrieb einer mobilen Lü...
12041	36124	cie. toula limnaios GmbH	Senatsverwaltung für Kultur und Europa	Projektförderung	2022	Eberswalder Straße 10, 10437 Berlin	kultur	Temporäre Anmietung einer mobilen Lüftungsanla...
31753	95260	Kultur Büro Elisabeth gGmbH	Senatsverwaltung für Kultur und Europa	Projektförderung	2021	Invalidenstraße 4 a, 10115 Berlin	kultur	Einbau, Anmietung und Betrieb einer mobilen Lü...
41336	124009	Radialsystem V GmbH	Senatsverwaltung für Kultur und Europa	Projektförderung	2021	Holzmarktstraße 33, 10243 Berlin	kultur	Temporäre Anmietung einer mobilen Lüftungsanla...
49911	149734	Theater Strahl gGmbH	Senatsverwaltung für Kultur und Europa	Projektförderung	2023	Martin-Luther-Straße 77, 10825 Berlin	kultur	Projekte "Wir holen uns die Nacht zurück " und...
51264	153793	Uferstudios GmbH	Senatsverwaltung für Kultur und Europa	Projektförderung	2021	Uferstraße 23, 13357 Berlin	kultur	Einbau,Anmietung und Betrieb einer mobilen Lüf...

Ergebnis

Der Datensatz weist ein deutliches Klassenungleichgewicht auf. Vor der Bereinigung enthält die Spalte **politikbereich** 34 Klassen.

Dabei wurden zwei auffällige Fälle identifiziert:

- **kultur** ist eine abweichende Schreibweise von **Kultur**,
- **Bürgerschaftliches Engagement** scheint inhaltlich zur größeren Klasse **Bürgerschaftliches Engagement, Bürgerbeteiligung** zu gehören.

Diese Fälle werden im weiteren Verlauf standardisiert, sodass die Zielvariable konsistenter verwendet werden kann.

1.3. Überprüfung der restlichen Textdaten auf inkonsistente Schreibweisen

Da die Spalte **politikbereich** Schreibvarianten und Unterkategorien enthält, werden auch die übrigen Textspalten auf inkonsistente Schreibweisen geprüft. Dazu gehören **name**, **geber**, **art**, **anschrift**, **zweck** und **empfaengerid**.

Ziel ist es zu prüfen, ob uneinheitliche Groß- und Kleinschreibung, Abkürzungen, Sonderzeichen, Leerzeichen oder Tippfehler die Anzahl scheinbar unterschiedlicher Werte künstlich erhöhen.

► Code

	name	geber	art	anschrift	zweck	empfaengerid
0	"AUSLÄNDER MIT UNS" - Verein zur Förderung int...	Bezirksamt Tempelhof-Schöneberg	Projektförderung	Geßlerstraße 11, 10829 Berlin	Vernetzung und Information aller Migrant_innen...	vr_004960
1	» mehrSicht « jugend*kultur*bildung e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	Pirolstraße 82, 12683 Berlin	Solidarisches Handeln? Welthandel erkunden f...	vr_038196
2	e. V.SV Preußen Berlin e. V.	Senatsverwaltung für Inneres und Sport	Projektförderung	Hansastraße 190, 13088 Berlin	Kosten für die Beschäftigung von hauptberuflic...	vr_011425
3	ITS Training Gesellschaft mit beschränkter Haf...	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	Am Oder-Spree-Kanal 23D, 12527 Berlin	Digitalprämie Berlin	hrb_084522
4	it's.BB e. V.	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	Poßweg 45, 14163 Berlin	Etablierung einer regionalen IT-/Cybersecurit...	vr_037100

Die Anzahl eindeutiger Werte nimmt nach der Normalisierung in mehreren Spalten ab. Dies bedeutet nicht zwangsläufig, dass Informationen verloren gegangen sind. Häufig werden lediglich unterschiedliche Schreibweisen desselben Wertes vereinheitlicht.

Dazu gehören beispielsweise:

- unterschiedliche Groß- und Kleinschreibung,
- überflüssige Leerzeichen,
- abweichende Schreibweisen von Abkürzungen,

- Unterschiede bei Satz- und Sonderzeichen.

Zur Überprüfung werden sowohl veränderte Einzelwerte als auch unterschiedliche Originalwerte dargestellt, die durch die Normalisierung zu einem gemeinsamen Wert zusammengeführt wurden.

1.3.1. Allgemeine Überprüfung und Normalisierung

► Code

► Code

► Code

Anzahl veränderter Werte: 285360

	column	row_index	original	normalized
0	name	0	"AUSLÄNDER MIT UNS" - Verein zur Förderung int...	"ausländer mit uns" - verein zur förderung int...
1	name	1	» mehrSicht « jugend*kultur*bildung e. V.	» mehrsicht « jugend*kultur*bildung e. v.
2	name	2	e. V.SV Preußen Berlin e. V.	e. v.sv preussen berlin e. v.
3	name	3	ITS Training Gesellschaft mit beschränkter Haf...	its training gesellschaft mit beschränkter haf...
4	name	4	it's.BB e. V.	it's.bb e. v.
5	name	5	it's.BB e. V.	it's.bb e. v.
6	name	6	it's.BB e. V.	it's.bb e. v.
7	name	7	Johannesstift Diakonie Jugendhilfe	johannesstift diakonie jugendhilfe
8	name	8	Umweltforum für Aktion und Zusammenarbeit e. V.	umweltforum für aktion und zusammenarbeit e. v.
9	name	9	"AUSLÄNDER MIT UNS" - Verein zur Förderung int...	"ausländer mit uns" - verein zur förderung int...

► Code

	column	normalized	Anzahl_Originalvarianten	Originalvarianten
694	anschrift	lützwstrasse 28, 10785 berlin	7	[Lützwstrasse 28, 10785 Berlin, Lützwstraße...

Spalte: anschrift
Normalisierter Wert: lützwstrasse 28, 10785 berlin
Anzahl der Varianten: 7

Originalvarianten	
0	Lützwstrasse 28, 10785 Berlin
1	Lützwstraße\n\n\n 28, 10785 Berlin
2	Lützwstraße\n\n 28, 10785 Berlin
3	Lützwstraße\n 28, 10785 Berlin
4	Lützwstraße\n 28, 10785 Berlin

Originalvarianten	
5	Lützowstraße 28, 10785 Berlin
6	Lützowstraße 28, 10785 Berlin

► Code

	column	original_unique	normalized_unique	merged_by_normalization	reduction_%
0	name	13393	13041	352	2.63
1	geber	43	43	0	0.00
2	art	3	2	1	33.33
3	anschrift	12125	11160	965	7.96
4	zweck	26875	26607	268	1.00
5	empfaengerid	10685	10668	17	0.16

Die Übersicht zeigt, welche Textspalten durch die reine Normalisierung tatsächlich zusammengeführt werden. Besonders bei Namen und Anschriften ist diese Reduktion relevant, weil unterschiedliche Schreibweisen sonst als verschiedene Einheiten gezählt würden. Gleichzeitig bleibt die Reduktion begrenzt, da rechtlich oder organisatorisch unterschiedliche Einträge nicht nur aufgrund ähnlicher Schreibweise zusammengelegt werden sollen.

1.3.2. Untersuchung der zusammenhängenden Textspalten

Zwischen den Empfängerdaten besteht ein enger Zusammenhang. Insbesondere `name`, `anschrift`, `jahr` und `empfaengerid` beschreiben teilweise dieselbe Organisation aus unterschiedlichen Perspektiven.

Diese Abhängigkeit ist für die Modellierung wichtig. Einerseits können solche Merkmale hilfreiche Informationen über den Politikbereich enthalten. Andererseits besteht das Risiko, dass ein Modell wiederkehrende Empfänger-, Namens- oder Adressmuster lernt, anstatt allgemein übertragbare inhaltliche Muster zu erkennen. Deshalb wird der Zusammenhang dieser Spalten genauer untersucht.

Untersuchung der mit der Empfänger-ID verbundenen Daten (`name`, `anschrift`, `jahr`)

► Code

	Beziehung	Übereinstimmungsrate	Übereinstimmungsrate_%
0	empfaengerid → name	0.896476	89.65
1	empfaengerid → anschrift	0.862861	86.29
2	empfaengerid + jahr → anschrift	0.928430	92.84
3	name + anschrift → empfaengerid	0.998821	99.88
4	empfaengerid + name + jahr → anschrift	0.945827	94.58

Die Ergebnisse zeigen einen starken Zusammenhang zwischen `name`, `anschrift` und `empfaengerid`. Besonders eindeutig ist die Kombination aus Name und Anschrift: In **99,88 %** der Fälle verweist sie auf dieselbe Empfänger-ID.

Eine Empfänger-ID ist zu **89,65 %** einem einheitlichen Namen und zu **86,29 %** einer einheitlichen Anschrift zugeordnet. Wird zusätzlich das Jahr berücksichtigt, steigt die Übereinstimmung der Anschrift auf **92,84 %**. Dies deutet darauf hin, dass sich Anschriften im Zeitverlauf ändern können.

Insgesamt beschreiben die drei Merkmale weitgehend denselben Empfänger. Die Beziehung ist jedoch aufgrund von Namensvarianten, Adressänderungen und möglichen Erfassungsunterschieden nicht vollständig eindeutig.

Daher wird zunächst geprüft, ob die Normalisierung und Standardisierung der Spalten `name` und `anschrift` zu einer einheitlicheren und konsistenteren Darstellung der Daten führt.

Untersuchung der Adressedaten

Adressangaben können viele oberflächliche Schreibvarianten enthalten, zum Beispiel `Str.`, `str`, `Strasse` oder `Straße`. Daher wird untersucht, ob die vorhandenen Adressdaten durch Normalisierung und spätere Standardisierung weiter vereinheitlicht werden können.

► Code

► Code

Anzahl veränderter Adressen: 136
Anzahl zusätzlich zusammengeführter Adressgruppen: 69

► Code

anschrift_normalized	Anzahl_Originalvarianten	Originalvarianten
0 axel-springer-strasse40/41, 10969 berlin	2	[axel-springer-str.40/41, 10969 berlin, axel-s...

Normalisierte Adresse: axel-springer-strasse40/41, 10969 berlin
Anzahl der Varianten: 2

Originalvarianten	
0	axel-springer-str.40/41, 10969 berlin
1	axel-springer-strasse40/41, 10969 berlin

Adresse nach Jahren

Zusätzlich wird geprüft, ob sich die Anschrift eines Empfängers im Zeitverlauf ändert. Dies ist wichtig, da unterschiedliche Anschriften nicht automatisch auf unterschiedliche Organisationen hinweisen müssen.

► Code

Anzahl der Empfänger-IDs mit einer Änderung der Google-standardisierten Anschrift zwischen den Jahren: 1679

Jahr	empfaengerid	2020	2021	2022	2023	2024
Anschriftversion		Anschrift	Anschrift	Anschrift	Anschrift	Anschrift
0	eb_100002	landsberger allee 116/117, 10407 berlin	landsberger allee 116/117a, 10407 berlin	stettiner strasse 21-23, 13357 berlin	stettiner strasse 21-23, 13357 berlin	stettiner strasse 21-23, 13357 berlin
1	eb_100004	gross-berliner damm 151-153, 12489 berlin	gross-berliner-damm 151-153, 12489 berlin	gross-berliner damm 151, 12489 berlin	gross-berliner damm 151, 12489 berlin	gross-berliner-damm 151-153, 12489 berlin
2	gnr_000142	NaN	NaN	hussitenstrasse 22 a, 13355 berlin	hussitenstrasse 22 a, 13355 berlin	hussitenstrasse 22a, 13355 berlin
3	gnr_000424	john-schehr-strasse 36, 10407 berlin	laubestrasse 2, 12045 berlin	NaN	kreuzbergstrasse 37/38 / aufgang 2, 10965 berlin	NaN
4	gnr_000434	NaN	ohlauer strasse 36, 10999 berlin	mariannenstrasse 48, 10997 berlin	NaN	NaN

Überprüfung der Namen

Grundsätzlich wird erwartet, dass eine Empfänger-ID einer Organisation zugeordnet ist. In den Daten zeigt sich jedoch, dass zu einer Empfänger-ID teilweise mehrere Namensvarianten vorkommen.

► Code

Anzahl der IDs mit mehreren Empfängernamen: 1505

	empfaengerid	Anzahl_Namen	Namen
0	nr_100309	13	[ib berlin-brandenburg, ib berlin-brandenburg ...
1	hrb_077849	12	[ev. elisabeth klinik, vivantes - netzwerk für...
2	vr_005628	11	[caritas für das erzbistum berlin, caritas für...
3	vr_009276	10	[nachbarschafts- und selbs- hilfezentrum in de...
4	vr_007649	10	[notdienst berlin e. v., notdienst e. v., notd...

Empfänger-ID: nr_100309

Anzahl der Namen: 13

	Namen
0	ib berlin-brandenburg
1	ib berlin-brandenburg ggmbh
2	ib berlin-brandenburg ggmbh region berlin südwest
3	ib berlin-brandenburg ggmbh region berlin südwest

Namen	
4	ib berlin-brandenburg ggmbh, kältehilfeeinrich...
5	internationaler bund (ib)
6	internationaler bund (ib) berlin-brandenburg
7	internationaler bund - ib berlin- brandenburg ...
8	internationaler bund - ib berlin- brandenburg ...
9	internationaler bund - ib berlin-brandenburg g...
10	internationaler bund - ib berlin-brandenburg g...
11	internationaler bund berlin-brandenburg
12	internationaler bund ib berlin-brandenburg ggmbh

Empfänger-ID: hrb_077849

Anzahl der Namen: 12

Namen	
0	ev. elisabeth klinik
1	vivantes - netzwerk für gesundheit gmbh
2	vivantes netzwerk für gesundheit - humboldt-kl...
3	vivantes netzwerk für gesundheit - ida wolff k...
4	vivantes netzwerk für gesundheit - klinikum am...
5	vivantes netzwerk für gesundheit - klinikum au...
6	vivantes netzwerk für gesundheit - klinikum im...
7	vivantes netzwerk für gesundheit - klinikum ka...
8	vivantes netzwerk für gesundheit - klinikum ne...
9	vivantes netzwerk für gesundheit - klinikum sp...
10	vivantes netzwerk für gesundheit - wenckebach-...
11	vivantes netzwerk für gesundheit gmbh

Empfänger-ID: vr_005628

Anzahl der Namen: 11

Namen	
0	caritas für das erzbistum berlin
1	caritas für das erzbistum berlin e. v. beratun...
2	caritasverband berlin
3	caritasverband für das erzbistum
4	caritasverband für das erzbistum berlin
5	caritasverband für das erzbistum berlin e. v.

	Namen
6	caritasverband für das erzbistum berlin e.v.
7	caritsverband für das erzbistum berlin
8	caritsverband für das erzbistum berlin ab 01.0...
9	caritsverband für das erzbistum berlin bis 31....
10	cartiasverbund für das erzbistum berlin

► Code

Vivantes-Datensätze:

	Name	Anschrift	Empfänger-ID
54856	vivantes - netzwerk für gesundheit gmbh	aroser allee 72-76, 13407 berlin	hrb_077849
54857	vivantes - netzwerk für gesundheit gmbh	aroser allee 72-76, 13407 berlin	hrb_077849
54858	vivantes - netzwerk für gesundheit gmbh	aroser allee 72-76, 13407 berlin	hrb_077849
54859	vivantes - netzwerk für gesundheit gmbh	aroser allee 72-76, 13407 berlin	hrb_077849
54860	vivantes - netzwerk für gesundheit gmbh	aroser allee 72-76, 13407 berlin	hrb_077849

Abweichende Datensätze:

	Name	Anschrift	Empfänger-ID
17342	ev. elisabeth klinik	lützwowstrasse 24-26, 10785 berlin	hrb_077849

Die Untersuchung der Empfängerinnenamen zeigt, dass einer Empfänger-ID teilweise mehrere Namensvarianten zugeordnet sind. Diese Unterschiede entstehen häufig durch Abkürzungen, Rechtschreibfehler, unterschiedliche Rechtsformen oder die zusätzliche Angabe einzelner Standorte und Organisationseinheiten.

Bei der Empfänger-ID **hrb_077849** beziehen sich beispielsweise fast alle Einträge auf die **Vivantes – Netzwerk für Gesundheit GmbH** oder auf einzelne Vivantes-Kliniken. Ein Datensatz enthält jedoch den Namen **Ev. Elisabeth Klinik** und gleichzeitig eine abweichende Anschrift. Da sowohl der Name als auch die Anschrift vom üblichen Muster dieser Empfänger-ID abweichen, handelt es sich wahrscheinlich nicht nur um eine Namensvariante, sondern möglicherweise um eine fehlerhafte Zuordnung der Empfänger-ID.

Daher werden ähnliche Namensvarianten unter einem kanonischen Namen zusammengeführt. Fälle, bei denen sowohl Name als auch Anschrift deutlich abweichen, werden dagegen nicht automatisch geändert, sondern für eine manuelle Prüfung markiert.

1.3.5. Untersuchung der kategorialen Spalten (**geber** , **art**)

► Code

	art	Anzahl
0	projektförderung	56096

	art	Anzahl
1	institutionelle förderung	1373

2. Datenvorbereitung

2.1. Normalisierung

Zunächst wird der DataFrame `df_normalized` verwendet, in dem die relevanten Textspalten bereits normalisiert wurden. Dadurch sind grundlegende Unterschiede in Groß- und Kleinschreibung, Leerzeichen sowie Sonderzeichen bereits vereinheitlicht.

► Code

	id	name	geber	art	jahr	anschrift	politikbereich	zweck	betra
0	1	"ausländer mit uns" - verein zur förderung int...	bezirksamt tempelhof-schöneberg	projektförderung	2022	gesslerstrasse 11, 10829 berlin	Integration	vernetzung und information aller migrant_innen...	1724
1	4	» mehrsicht « jugend*kultur*bildung e. v.	senatsverwaltung für wirtschaft, energie und b...	projektförderung	2024	pirolstrasse 82, 12683 berlin	Wirtschaft	solidarisches handeln? welthandel erkunden f...	4000
2	7	e. v.sv preussen berlin e. v.	senatsverwaltung für inneres und sport	projektförderung	2021	hansastrasse 190, 13088 berlin	Sport	kosten für die beschäftigung von hauptberuflic...	4070
3	10	its training gesellschaft mit beschränkter haf...	senatsverwaltung für wirtschaft, energie und b...	projektförderung	2021	am oder-spree-kanal 23d, 12527 berlin	Wirtschaft	digitalprämie berlin	4066
4	13	it's.bb e. v.	senatsverwaltung für wirtschaft, energie und b...	projektförderung	2024	possweg 45, 14163 berlin	Wirtschaft	etablierung einer regionalen it-/cybersecurit...	46489

2.2. Standardisierung des Politikbereichs

Auf Basis der EDA werden auffällige Schreibweisen und fachlich naheliegende Unterkategorien in der Zielvariable standardisiert. Dadurch soll die Zielspalte konsistenter werden, ohne die fachliche Struktur der Daten unnötig zu verändern.

Beobachtungen aus der EDA:

1. **kultur** scheint lediglich eine abweichende Schreibweise von **Kultur** zu sein. Daher wird **kultur** zur einheitlichen Darstellung auf **Kultur** geändert.
2. **Bürgerschaftliches Engagement** scheint zur größeren Klasse **Bürgerschaftliches Engagement, Bürgerbeteiligung** zu gehören, da beide Bezeichnungen bei ähnlichen Empfängern und Förderarten verwendet werden.


Diese beiden Fälle werden deshalb in die jeweils konsistentere Zielklasse überführt.

► Code

► Code

'Anzahl der Klassen: 32'

<Figure size 1000x1000 with 0 Axes>



Politikbereich	Count
Wirtschaft	11349
Arbeit	7851
Sport	6041
Jugend	5996
Kultur	4692
Bildung	3372
Soziales	2865
Gesundheit	2824
Bürgerschaftliches Engagement, Bürgerbeteiligung	1759
Integration	1722
Stadtentwicklung	1360
Familie	1264
Umwelt	1150
Verkehr	1105
Antidiskriminierung	844
Gleichstellung	638
Pflege	549
Forschung	282
Denkmalschutz	264
Frauen	238
Justiz	230
Kirchen, Religions-, Weltanschauungsgemeinschaften	219
Wissenschaft	204
Verbraucherschutz	201
Sicherheit, Ordnung	162
Europa	106
Bauen, Wohnen	104
Internationales	27
Medien	19
Finanzen	18
Tierschutz	9
Berlin-Image	5

Nach der Bereinigung und Neuordnung enthält die Zielvariable insgesamt **32 Klassen**. Die Klassenverteilung bleibt jedoch weiterhin stark unausgewogen. Häufige Klassen wie **Wirtschaft** haben sehr viele Einträge, während sehr kleine Klassen wie **Berlin-Image** nur wenige Beobachtungen enthalten.

Diese Klassenunverteilung wird später bei der Modellbewertung berücksichtigt, insbesondere durch Macro-F1, Balanced Accuracy und klassenbezogene Metriken.

2.3. Standardisierung der Anschrift durch Google Geocoding API

Eine vollständige manuelle Standardisierung sämtlicher Adressdaten wäre jedoch weder realistisch noch effizient, da dafür jeder Einzelfall separat geprüft werden müsste. Daher werden die Adressen mithilfe einer Maps-API automatisiert gesucht, überprüft und in ein einheitliches Format überführt.

- Code
- Code
- Code
- Code

Anzahl eindeutiger Anschriften vor der Google-Suche: 11091

- Code
- Code
- Code
- Code

Anzahl der Datensätze: 57469
Anzahl erfolgreicher Google-Zuordnungen: 55831

	anschrift_original	anschrift_vor_google	anschrift_google_standardised	google_status	partial_match
0	gesslerstrasse 11, 10829 berlin	gesslerstrasse 11, 10829 berlin	Geßlerstraße 11, 10829 Berlin-Bezirk Tempelhof...	OK	False
1	pirolstrasse 82, 12683 berlin	pirolstrasse 82, 12683 berlin	Pirolstraße 82, 12683 Berlin-Bezirk Marzahn-He...	OK	False
2	hansastrasse 190, 13088 berlin	hansastrasse 190, 13088 berlin	Hansastraße 190, 13088 Berlin, Deutschland	OK	False
3	am oder-spree-kanal 23d, 12527 berlin	am oder-spree-kanal 23d, 12527 berlin	Am Oder-Spree-Kanal 23D, 12527 Berlin-Bezirk T...	OK	False
4	possweg 45, 14163 berlin	possweg 45, 14163 berlin	Poßweg 45, 14163 Berlin-Bezirk Steglitz-Zehlen...	OK	False
5	possweg 45 c/o nkmg, 14163 berlin	possweg 45 c/o nkmg, 14163 berlin	Poßweg 45, 14163 Berlin-Bezirk Steglitz-Zehlen...	OK	False
6	possweg 45, 14163 berlin	possweg 45, 14163 berlin	Poßweg 45, 14163 Berlin-Bezirk Steglitz-Zehlen...	OK	False

	anschrift_original	anschrift_vor_google	anschrift_google_standardised	google_status	partial_match
7	schönwalder allee 26/45, 13587 berlin	schönwalder allee 26/45, 13587 berlin	Schönwalder Allee 26/45, 13587 Berlin, Deutsch...	OK	False
8	hermannstrasse 29, 14163 berlin	hermannstrasse 29, 14163 berlin	Hermannstraße 29, 14163 Berlin-Bezirk Steglitz...	OK	False
9	gesslerstrasse 11, 10829 berlin	gesslerstrasse 11, 10829 berlin	Geßlerstraße 11, 10829 Berlin-Bezirk Tempelhof...	OK	False

► Code

Anzahl eindeutiger, durch Google veränderter Anschriften: 10402

	anschrift_original	anschrift_vor_google	anschrift_google_standardised
0	gesslerstrasse 11, 10829 berlin	gesslerstrasse 11, 10829 berlin	Geßlerstraße 11, 10829 Berlin-Bezirk Tempelhof...
1	pirolstrasse 82, 12683 berlin	pirolstrasse 82, 12683 berlin	Pirolstraße 82, 12683 Berlin-Bezirk Marzahn-He...
2	hansastrasse 190, 13088 berlin	hansastrasse 190, 13088 berlin	Hansastraße 190, 13088 Berlin, Deutschland
3	am oder-spree-kanal 23d, 12527 berlin	am oder-spree-kanal 23d, 12527 berlin	Am Oder-Spree-Kanal 23D, 12527 Berlin-Bezirk T...
4	possweg 45, 14163 berlin	possweg 45, 14163 berlin	Poßweg 45, 14163 Berlin-Bezirk Steglitz-Zehlen...
5	possweg 45 c/o nkmg, 14163 berlin	possweg 45 c/o nkmg, 14163 berlin	Poßweg 45, 14163 Berlin-Bezirk Steglitz-Zehlen...
6	schönwalder allee 26/45, 13587 berlin	schönwalder allee 26/45, 13587 berlin	Schönwalder Allee 26/45, 13587 Berlin, Deutsch...
7	hermannstrasse 29, 14163 berlin	hermannstrasse 29, 14163 berlin	Hermannstraße 29, 14163 Berlin-Bezirk Steglitz...
8	sokratesweg 85, 10318 berlin	sokratesweg 85, 10318 berlin	Sokratesweg 85, 10318 Berlin-Bezirk Lichtenber...
9	reinhold-würth-strasse 12-17, 74653 künzelau	reinhold-würth-strasse 12-17, 74653 künzelau	Reinhold-Würth-Straße 12-17, 74653 Künzelsau-G...

► Code

Anzahl zusätzlich durch Google zusammengeführter Adressgruppen: 1116

► Code

Google-standardisierte Anschrift: Obentrautstraße 16/18, 10963 Berlin-Bezirk Friedrichshain-Kreuzberg, Deutschland

Anzahl der zusammengeführten Varianten: 16

	Anschrift_vor_Google
0	obentrautstrasse 16 - 18, 10119 berlin
1	obentrautstrasse 16 - 18, 10318 berlin
2	obentrautstrasse 16 - 18, 10557 berlin
3	obentrautstrasse 16 - 18, 10719 berlin
4	obentrautstrasse 16 - 18, 10963 berlin
5	obentrautstrasse 16 - 18, 10969 berlin
6	obentrautstrasse 16 - 18, 10997 berlin
7	obentrautstrasse 16 - 18, 12277 berlin
8	obentrautstrasse 16 - 18, 12679 berlin
9	obentrautstrasse 16 - 18, 12681 berlin
10	obentrautstrasse 16 - 18, 13086 berlin
11	obentrautstrasse 16 - 18, 13129 berlin
12	obentrautstrasse 16 - 18, 13156 berlin
13	obentrautstrasse 16 - 18, 13347 berlin
14	obentrautstrasse 16 - 18, 13507 berlin
15	obentrautstrasse 16 - 18, 13597 berlin

► Code

	Verarbeitungsschritt	Eindeutige_Anschriften	Reduktion_zum_Vorschritt	Reduktion_zum_Vorschritt_%
0	Originaldaten	11160	0	0.00
1	Eigene Normalisierung	11091	69	0.62
2	Normalisierung + Google-Maps-Standardisierung	9711	1380	12.44

► Code

Vergleich der Adressenkonsistenz vor und nach der Google-Maps-Standardisierung:

Datenstand	Beziehung	Nach Google	Vor Google	Veränderung_in_Prozentpunkten
0	empfaengerid + jahr → anschrift	95.44	92.92	2.52
1	empfaengerid → anschrift	90.44	86.41	4.03

Die Google-Standardisierung verbessert vor allem die Konsistenz der Anschriften. Der stärkere Zusammenhang zwischen Empfänger-ID, Jahr und Anschrift zeigt, dass ein Teil der vorherigen Abweichungen auf unterschiedliche Schreibweisen oder unvollständige Adressangaben zurückzuführen war. Teiltreffer und unsichere Ergebnisse werden jedoch nicht automatisch übernommen, um falsche Zusammenführungen zu vermeiden.

2.4. Normalisierung und Standardisierung der Namen

Über die [Transparenzdatenbank des Landes Berlin](#) lässt sich anhand der Empfänger-ID die offizielle Bezeichnung einer Organisation ermitteln. Hierzu wurden die öffentlich zugänglichen Organisationsnamen und die zugehörigen Empfänger-IDs automatisiert ausgelesen und anschließend in einer CSV-Datei für die weitere Datenverarbeitung gespeichert.

► Code

Anzahl der Organisationen: 23500

	name	empfaengerid	letzte_datenaktualisierung	transparenz_detail_id	detail_url
0	!K7 Records GmbH	hrb_060789	14.10.2019	C350B31290A88A003D5008F8FAFF16FC	https://transp
1	!KF - Institut für künstlerische Forschung	vr_028872	14.10.2022	C3B6BC3A70A441407DB36361B8B16D95	https://transp
2	!Respect e. V.	nr_101426	18.10.2024	121A1DC542713D98355203221BD3A4BA	https://transp
3	" E S B E R " Verwaltungsgesellschaft mit besc...	hrb_001875	NaN	21C8DA8994AE5FC56CD263DA0FDBD521	https://transp
4	"Berliner Jugendclub" - Stätte der Begegnung -	vr_003027	09.03.2020	8CD56A3AA26704E388A946011EB29ADE	https://transp



Die ursprünglichen Werte in den Spalten `name` und `empfaengerid` werden zunächst beibehalten. Fehlende Empfänger-IDs werden nur dann anhand der Kombination aus standardisiertem Namen und Google-standardisierter Anschrift ergänzt, wenn diese Kombination in den vorhandenen Daten mehrfach und eindeutig derselben ID zugeordnet ist.

Anschließend wird für jede Empfänger-ID der häufigste Name als kanonische Bezeichnung bestimmt. Weichen bei einem Datensatz sowohl der Name als auch die Anschrift vom typischen Muster der ID ab, wird dieser nicht automatisch geändert, sondern zur manuellen Prüfung markiert. Dadurch sollen fehlerhafte Zusammenführungen unterschiedlicher Organisationen vermieden werden.

► Code

Transparenzdaten normalisieren

► Code

	name	empfaengerid
0	!k7 records gmbh	hrb_060789
1	!kf - institut für künstlerische forschung	vr_028872
2	!respect e. v.	nr_101426
3	" e s b e r " verwaltungsgesellschaft mit besc...	hrb_001875

	name	empfaengerid
4	"berliner jugendclub" - stätte der begegnung -	vr_003027

Referenztable mit offiziellen Organisationsnamen

► Code

Anzahl der Organisationen in der Referenztable: 23500

	entity_id_official	name_official	name_official_normalized
0	hrb_060789	!K7 Records GmbH	!k7 records gmbh
1	vr_028872	!KF - Institut für künstlerische Forschung	!kf - institut für künstlerische forschung
2	nr_101426	!Respect e. V.	!respect e. v.
3	hrb_001875	" E S B E R " Verwaltungsgesellschaft mit besc...	" e s b e r " verwaltungsgesellschaft mit besc...
4	vr_003027	"Berliner Jugendclub" - Stätte der Begegnung -	"berliner jugendclub" - stätte der begegnung -

► Code

Vergleichsnamen vorbereiten

Für den Vergleich werden Satzzeichen und Rechtsformen entfernt. Die offiziellen Namen selbst bleiben unverändert.

► Code

Exakte Übereinstimmung und Namensbestandteile

Die exakte Übereinstimmung besitzt die höchste Priorität. Danach wird geprüft, ob ein vollständiger Name als Wortfolge im jeweils anderen Namen enthalten ist.

► Code

Ergänzende Namensähnlichkeiten

RapidFuzz berücksichtigt abweichende Wortreihenfolgen und zusätzliche Namensbestandteile. Character-n-Gramme erfassen insbesondere Tippfehler, Bindestriche und kleinere Schreibvarianten.

► Code

► Code

Abkürzungen und Organisationseinheiten

Abkürzungen und typische Bezeichnungen von Standorten oder Einrichtungen werden als eigenständige Signale behandelt.

► Code

Eindeutige offizielle Namen für fehlende IDs

Eine fehlende Empfänger-ID wird nur ergänzt, wenn der normalisierte offizielle Name eindeutig genau einer ID zugeordnet ist.

► Code

Hierarchische Zuordnung

Die Signale werden nicht zu einem schwer erklärbaren Mittelwert zusammengefasst, sondern in einer festen Reihenfolge ausgewertet.

► Code

► Code

Ergebnisübersicht der Namenszuordnung

► Code

	match_method	needs_review	Anzahl	Anteil_%
5	official_id_exact	False	43457	75.62
2	official_id_containment	False	8135	14.16
10	unmatched	True	1482	2.58
4	official_id_context_supported_match	False	1326	2.31
6	official_id_fuzzy_containment	False	834	1.45
7	official_id_name_conflict	True	828	1.44
1	official_id_acronym	False	731	1.27
9	official_id_strong_fuzzy_match	False	366	0.64
3	official_id_containment_with_unit	False	203	0.35
0	id_not_found	True	83	0.14
8	official_id_official_name_with_addition	False	24	0.04

```
needs_review
False    95.84
True      4.16
Name: Anteil_%, dtype: float64
```

► Code

	review_reason	Anzahl	Anteil_an_Gesamtdaten_%
1	missing_id_and_no_exact_official_name	1482	2.58
2	official_id_name_conflict	828	1.44
0	id_not_found_in_transparency_database	83	0.14

Die ErgebnisÜbersicht trennt verlässliche automatische Zuordnungen von Fällen, die weiterhin geprüft werden müssen. Dadurch wird verhindert, dass offizielle Namen aus der Transparenzdatenbank blind übernommen werden, wenn Name, ID oder Kontext nicht ausreichend zusammenpassen. Für die Modellierung werden nur die zuverlässig standardisierten Fälle verwendet.

► Code

355 Eindeutige Datensätze mit fehlender Empfänger-ID in Transparenzdatenbank

Beispiel:

	name_normalized	name_official_normalized	empfaengerid_original	name_relation	rapidfuzz_wratio
53601	verschiedene natürliche personen	NaN	0	unexplained_difference	NaN
23987	grün berlin gmbh	NaN	hbr_015772	unexplained_difference	NaN
10813	caritas krankenhilfe berlin ggmbh	NaN	hrb_213073	unexplained_difference	NaN
32297	kulturveranstaltungen des bundes in berlin gmbh...	NaN	hrb_029257	unexplained_difference	NaN
23833	grone bildungszentren berlin ggmbh	NaN	hrb_056919	unexplained_difference	NaN
15656	dreieins innovative pädagogik ggmbh	NaN	hrb_094898	unexplained_difference	NaN
47462	stiftung innovation in der hochschullehre,treu...	NaN	hrb_142764	unexplained_difference	NaN
14978	dico gesellschaft für community organizing ggmbh	NaN	hrb_147206	unexplained_difference	NaN
15623	drehandel gmbh	NaN	hrb_148898	unexplained_difference	NaN
28879	katholische pfarrgemeinde herz jesu und st. ju...	NaN	kör_100116	unexplained_difference	NaN

► Code

	name_normalized	name_official_normalized	empfaengerid_original	entity_id_official	entity_id	na
0	kindertagesstätten nordwest eigenbetrieb von b...	kindertagesstätten südost, eigenbetrieb von be...	eb_100004	eb_100004	eb_100004	un

	name_normalized	name_official_normalized	empfaengerid_original	entity_id_official	entity_id	na
1	mietergenossen-schaft selbstbau e.g.	selbstbaugenossenschaft berlin e.g.	gnr_000424	gnr_000424	gnr_000424	un
2	gewerbehof saarbrücker strasse eg	genossenschaft in der alten königstadtbrauerei eg	gnr_000538	gnr_000538	gnr_000538	un
3	wbg „bremer höhe“ eg	wohnungsbaugenossenschaft "bremer höhe" e. g.	gnr_000569	gnr_000569	gnr_000569	un
4	wbg „am ostseeplatz“ eg	wohnungsbaugenossenschaft "am ostseeplatz" eg	gnr_000577	gnr_000577	gnr_000577	un
5	howoge wohnungsbaugesellschaft mbh	degewo aktiengesellschaft	hrb_001217	hrb_001217	hrb_001217	un
6	gewobag pb wohnen in prenzlauer berg gmbh	gewobag wohnungsbau- aktiengesellschaft berlin	hrb_003445	hrb_003445	hrb_003445	un
7	havelländische eisenbahn ag	niederbarnimer eisenbahn- aktiengesellschaft	hrb_007522	hrb_007522	hrb_007522	un
8	dominikus krankenhaus berlin hermsdorf	caritas-klinik dominikus berlin- reinickendorf ...	hrb_009954	hrb_009954	hrb_009954	un
9	holzmanufaktur in kreuzberg gmbh	tischlerei holzmanufaktur in berlin gmbh	hrb_011925	hrb_011925	hrb_011925	un
10	az gmbh personalkonzepte	az gmbh personalberatung	hrb_017402	hrb_017402	hrb_017402	un
11	gsp sprachtechnologie gmbh	televic rail gmbh	hrb_022455	hrb_022455	hrb_022455	un
12	e.t.-elektrobau gmbh	et-elektrobau gesellschaft für elektrotechnisc...	hrb_022830	hrb_022830	hrb_022830	un
13	asum angewandte sozialforschung und urbanes ma...	asum angewandte stadtforschung und mieterberat...	hrb_024440	hrb_024440	hrb_024440	un
14	dr. gabriele minz unternehmensberatung projekt...	dr. gabriele minz internationale kulturprojekt...	hrb_025763	hrb_025763	hrb_025763	un
15	arktis gesellschaft für telekommunikation und ...	arktis it solutions gmbh	hrb_028236	hrb_028236	hrb_028236	un
16	quadrat grundstücksverw. gmbh	quadrat grundstücksverwaltungsgesellschaft mbh	hrb_030057	hrb_030057	hrb_030057	un
17	rebu ingenieurgesellschaft für stahlbauten und...	bsb maschinenbau gmbh	hrb_036769	hrb_036769	hrb_036769	un
18	polyprint druck und kopierservice werbung	pos werbetechnik berlin gmbh	hrb_038665	hrb_038665	hrb_038665	un

	name_normalized	name_official_normalized	empfaengerid_original	entity_id_official	entity_id	na
	spez...					
19	bbw hochschule	bbw akademie für betriebswirtschaftliche weite...	hrb_038757	hrb_038757	hrb_038757	un

Finale Bereinigungsspalten definieren

► Code

	name_normalized	name_official_normalized	name_canonical	organisationseinheit	empfaengerid_original
0	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960
1	» mehrsicht « jugend*kultur*bildung e. v.	» mehrsicht « jugend*kultur*bildung e. v.	» mehrsicht « jugend*kultur*bildung e. v.	<NA>	vr_038196
2	e. v.sv preussen berlin e. v.	sportverein preussen berlin e. v.	sportverein preussen berlin e. v.	<NA>	vr_011425
3	its training gesellschaft mit beschränkter haf...	its training gesellschaft mit beschränkter haf...	its training gesellschaft mit beschränkter haf...	<NA>	hrb_084522
4	it's.bb e. v.	it's.bb e. v.	it's.bb e. v.	<NA>	vr_037100
5	it's.bb e. v.	it's.bb e. v.	it's.bb e. v.	<NA>	vr_037100
6	it's.bb e. v.	it's.bb e. v.	it's.bb e. v.	<NA>	vr_037100
7	johannesstift diakonie jugendhilfe	johannesstift diakonie jugendhilfe ggmbh	johannesstift diakonie jugendhilfe ggmbh	jugendhilfe	hrb_124070
8	umweltforum für aktion und zusammenarbeit e. v.	umweltforum für aktion und zusammenarbeit e. v.	umweltforum für aktion und zusammenarbeit e. v.	<NA>	vr_027417
9	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960
10	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960
11	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960
12	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960

	name_normalized	name_official_normalized	name_canonical	organisationseinheit	empfaengerid_original
13	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	verein zur förderung interkultureller begegnun...	<NA>	vr_004960
14	edusation gemeinnützige gesellschaft für integ...	edusation - gemeinnützige gesellschaft für int...	edusation - gemeinnützige gesellschaft für int...	<NA>	hrb_177205
15	gemeinnützige stiftung wüsth (anne- sophie)	stiftung wüsth	stiftung wüsth	<NA>	spr_100040
16	serbisch-deutsche gemeinde - mladost- berlin e...	serbisch-deutsche gemeinde - mladost- berlin e...	serbisch-deutsche gemeinde - mladost- berlin e...	<NA>	vr_004218
17	serbisch-deutsche gemeinde - mladost- berlin e...	serbisch-deutsche gemeinde - mladost- berlin e...	serbisch-deutsche gemeinde - mladost- berlin e...	<NA>	vr_004218
18	theater o.n. e. v.	theater o.n. e. v.	theater o.n. e. v.	<NA>	vr_016357
19	!respect e. v.	!respect e. v.	!respect e. v.	<NA>	nr_101426

Standardisierung des Empfängernamens

Der offizielle Name wird nur für Datensätze übernommen, deren Zuordnung keine manuelle Prüfung erfordert (`needs_review == False`). Bei unsicheren Datensätzen bleibt der bisher normalisierte Name erhalten. Dadurch werden bestätigte Namensvarianten vereinheitlicht, ohne ungeklärte Fälle automatisch zu überschreiben.

► Code

	column	original_unique	standardised_unique	merged_by_standardisation	reduction_%	standardised_rows	changed
0	name	13041	10865	2176	16.69	55076	11619

◀  ▶

	name_normalized	name_standardised	entity_id	match_method	match_confidence
0	"ausländer mit uns" - verein zur förderung int...	verein zur förderung interkultureller begegnun...	vr_004960	official_id_fuzzy_containment	0.92
2	e. v.sv preussen berlin e. v.	sportverein preussen berlin e. v.	vr_011425	official_id_context_supported_match	0.87
7	johannesstift diakonie jugendhilfe	johannesstift diakonie jugendhilfe ggmbh	hrb_124070	official_id_containment_with_unit	0.97
14	edusation gemeinnützige gesellschaft für integ...	edusation - gemeinnützige gesellschaft für int...	hrb_177205	official_id_containment	0.95

	name_normalized	name_standardised	entity_id	match_method	match_confidence
15	gemeinnützige stiftung wüsth (anne- sophie)	stiftung wüsth	spr_100040	official_id_containment	0.95
45	"roter baum" berlin gug	unternehmergesellschaft (haftungsbeschränkt) "...	hrb_135916	official_id_containment	0.95
49	"zuhaus im kiez" zik gesellschaft zur bessere...	zik - zuhaus im kiez ggmbh	hrb_031751	official_id_fuzzy_containment	0.92
54	„alice-salomon“- hochschule für sozialarbeit un...	alice salomon hochschule berlin	kör_100074	official_id_fuzzy_containment	0.92
77	1. berliner inklusions- tauchclub e. v.	1. berliner inklusions tauchclub e. v.	vr_034526	official_id_containment	0.95
78	1. berliner skateboard verein e. v.	1. berliner skateboard- verein e. v.	vr_005600	official_id_containment	0.95

2.5 Empfänger-ID rekonstruieren

Fehlende Empfänger-IDs werden nur dann ergänzt, wenn die vorhandenen Daten eine eindeutige Zuordnung erlauben. Zuerst wird eine exakte interne Referenz aus Name und Google-standardisierter Anschrift geprüft. Danach werden für verbleibende Fälle mögliche Organisationen aus der Transparenzdatenbank über seltene Namenstoken gesucht und deren Anschriften mit Google Places verifiziert.

Ausgangsdaten und ausschließbare Sammelbezeichnungen

Bezeichnungen wie „Verschiedene natürliche Personen“ stehen nicht für eine einzelne Organisation und können deshalb keiner eindeutigen Empfänger-ID zugeordnet werden. Für die weitere Suche werden nur fehlende IDs mit einem konkreten Namen und einer verwertbaren Anschrift berücksichtigt.

► Code

Datensätze ohne ursprüngliche Empfänger-ID: 1482

Davon konkrete eindeutige Namen mit verwertbarer Anschrift: 5

Methode 1: Eindeutige interne Zuordnung über Name und Anschrift

Bereits vorhandene IDs dienen als Referenz. Eine fehlende ID wird nur vorgeschlagen, wenn dieselbe Kombination aus kompaktem Vergleichsnamen und Google-standardisierter Anschrift in den Bestandsdaten ausschließlich zu einer einzigen Empfänger-ID gehört. Diese Methode benötigt keine unscharfe Ähnlichkeit und hat daher die höchste Priorität.

► Code

Durch exakten Namen und exakte Anschrift rekonstruierbar: 1

	source_row_index	name_normalized	anschrift_google_standardised	entity_id_from_exact_name_address
24446	24446	handball club schöneberg 77 e. v.	Goldfinkweg 44, 14195 Berlin-Bezirk Charlotten...	nr_100293

Methode 2: Kandidaten aus der Transparenzdatenbank

Eine Google-Suche für alle Organisationen wäre unnötig und kostenintensiv. Deshalb werden zuerst nur offizielle Namen ausgewählt, die mit dem fehlenden Namen mindestens ein seltenes, aussagekräftiges Token teilen. Allgemeine Wörter wie „Berlin“, „Verein“ oder „Gesellschaft“ werden bei der Kandidatensuche nicht berücksichtigt. Pro fehlendem Namen werden höchstens zehn Kandidaten weiterverarbeitet.

► Code

Fehlende Namen mit mindestens einem offiziellen Kandidaten: 4
Eindeutige offizielle Namen für die Google-Suche: 32

Offizielle Organisationsanschriften mit Google Places suchen

Nur die zuvor gebildeten Kandidaten werden über Places Text Search gesucht. Angefordert werden ausschließlich Place-ID, Anzeigenname und formatierte Anschrift. Bereits vorhandene Ergebnisse werden aus einer lokalen Cache-Datei geladen, damit dieselbe kostenpflichtige Anfrage nicht wiederholt wird.

► Code

Neue Google-Places-Abfragen: 0
Offizielle Kandidaten mit Places-Treffer: 31

Anschriften komponentenweise vergleichen

Eine automatische Zuordnung verlangt dieselbe Postleitzahl und Hausnummer. Der Straßensname darf kleine Schreibunterschiede enthalten und wird deshalb mit RapidFuzz verglichen. Eine Empfänger-ID gilt nur dann als rekonstruierbar, wenn genau eine offizielle ID diese Adressbedingungen erfüllt.

► Code

Durch Transparenzdatenbank und Google Places rekonstruierbar: 1

	name_missing	address_missing	name_official_candidate	entity_id_candidate	formatted_address	street_similarity
34	institut francais	Kurfürstendamm 211, 10719 Berlin-Bezirk Charl...	Centre Francais de Berlin - deutsch-französisch...	hrb_058123	Kurfürstendamm 211, 10719 Berlin	1.0

Rekonstruktion anwenden und Ergebnis kontrollieren

Die interne exakte Zuordnung wird zuerst angewendet. Google-Places-Treffer ergänzen nur bislang ungelöste Zeilen. Die ursprüngliche Spalte bleibt unverändert; die rekonstruierte ID wird in `entity_id` gespeichert und die

verwendete Methode separat dokumentiert.

► Code

	Methode	Anzahl
0	Exakter Name + Google-standardisierte Anschrift	1
1	Transparenzname + Google-Places-Anschrift	1
2	Insgesamt rekonstruiert	2
3	Weiterhin ohne Empfänger-ID	1480

	name_normalized	anschrift_google_standardised	entity_id	entity_id_reconstruction_method	mat
24446	handball club schöneberg 77 e. v.	Goldfinkweg 44, 14195 Berlin- Bezirk Charlotten...	nr_100293	exact_name_and_google_address	0.99
26617	institut francais	Kurfürstendamm 211, 10719 Berlin-Bezirk Charl...	hrb_058123	transparency_name_and_google_place_address	0.95

Die Rekonstruktion fehlender Empfänger-IDs wird bewusst konservativ durchgeführt. Eine ID wird nur ergänzt, wenn Name und Anschrift ausreichend eindeutige Hinweise liefern. Unsichere Kandidaten bleiben ausgeschlossen, weil eine falsche Empfänger-ID später zu Datenleckage oder fehlerhaften institutionellen Mustern im Modell führen könnte.

2.6. Überprüfung der Textspalten nach der Normalisierung und Standardisierung

Wiederverwendbare Verarbeitung aller Textspalten

Die Textverarbeitung wird in drei wiederverwendbare Schritte aufgeteilt. Zuerst werden Unicode, Groß- und Kleinschreibung sowie Leerzeichen mit `normalize_text` vereinheitlicht. Danach werden die bereits geprüften Standardwerte für Name, Anschrift und Empfänger-ID übernommen. Für `geber`, `art` und `zweck` bleibt die allgemeine Normalisierung gleichzeitig der Standardwert, da dafür keine zusätzliche Referenzquelle verwendet wurde.

► Code

Normalisierung und Standardisierung in einem Durchlauf anwenden

Alle definierten Textspalten werden gemeinsam verarbeitet. Die Originalspalten bleiben unverändert; die Ergebnisse werden transparent in den Suffixen `_normalized` und `_standardised` gespeichert. Anschließend zeigt die Reduktionstabelle, wie viele Schreibvarianten in jedem Verarbeitungsschritt zusammengeführt wurden.

► Code

Datensätze für die weitere Analyse: 57469

	column	original_unique	normalized_unique	standardised_unique	merged_by_normalization	merged_by_stand
0	name	13393	13041	10864	352	2177
1	geber	43	43	43	0	0
2	art	3	2	2	1	0
3	anschrift	12125	11160	9711	965	1449
4	zweck	26875	26607	26607	268	0
5	empfaengerid	10685	10668	10668	17	0

► Code

► Code

Zusammenfassung der ursprünglichen Textspalten:

	column	total_rows	missing_count	non_null_count	unique_count	unique_ratio_%	duplicated_rows	duplicated
0	name	57469	0	57469	13393	23.30	50785	88.37
1	geber	57469	0	57469	43	0.07	57469	100.00
2	art	57469	0	57469	3	0.01	57469	100.00
3	anschrift	57469	0	57469	12125	21.10	51641	89.86
4	zweck	57469	1	57468	26875	46.77	37498	65.25
5	empfaengerid	57469	1482	55987	10685	19.08	51130	91.32

Zusammenfassung nach der Normalisierung:

	column	total_rows	missing_count	non_null_count	unique_count	unique_ratio_%	duplicated_rows	duplicated
0	name	57469	0	57469	13041	22.69	51020	88.78
1	geber	57469	0	57469	43	0.07	57469	100.00
2	art	57469	0	57469	2	0.00	57469	100.00
3	anschrift	57469	0	57469	11160	19.42	52229	90.88
4	zweck	57469	1	57468	26607	46.30	37817	65.81
5	empfaengerid	57469	1482	55987	10668	19.05	51141	91.34

Zusammenfassung nach der Standardisierung:

	column	total_rows	missing_count	non_null_count	unique_count	unique_ratio_%	duplicated_rows	duplicated
0	name	57469	0	57469	10864	18.90	52470	91.30
1	geber	57469	0	57469	43	0.07	57469	100.00
2	art	57469	0	57469	2	0.00	57469	100.00

	column	total_rows	missing_count	non_null_count	unique_count	unique_ratio_%	duplicated_rows	duplicated
3	anschrift	57469	0	57469	9711	16.90	53309	92.76
4	zweck	57469	1	57468	26607	46.30	37817	65.81
5	empfaengerid	57469	1480	55989	10668	19.05	51143	91.34

Die Spalten **geber** und **art** können als kategoriale Merkmale betrachtet werden.

Die Spalte **geber** enthält bei insgesamt 57.469 Datensätzen nur **43 unterschiedliche Werte**. Dies entspricht einem Anteil von lediglich **0,07 %**. Außerdem kommt jeder Wert mehrfach vor, da es keine Werte gibt, die nur einmal auftreten.

Die Spalte **art** weist sogar nur **zwei unterschiedliche Werte** auf. Ihr Anteil eindeutiger Werte beträgt fast **0 %**. Auch hier treten alle vorhandenen Werte mehrfach auf.

Die geringe Anzahl unterschiedlicher Werte und deren häufige Wiederholung zeigen, dass beide Spalten aus einer begrenzten Menge festgelegter Kategorien bestehen. Daher sind **geber** und **art** als **kategoriale Variablen** einzustufen.

► Code

Beziehungen vor der Normalisierung und Standardisierung:

	Beziehung	Übereinstimmungsrate	Übereinstimmungsrate_%
0	empfaengerid → name	0.896476	89.65
1	empfaengerid → anschrift	0.862861	86.29
2	empfaengerid + jahr → anschrift	0.928430	92.84
3	name + anschrift → empfaengerid	0.998821	99.88
4	empfaengerid + name + jahr → anschrift	0.945827	94.58

Beziehungen nach der Normalisierung und Standardisierung:

	Beziehung	Übereinstimmungsrate	Übereinstimmungsrate_%
0	empfaengerid → name	0.992820	99.28
1	empfaengerid → anschrift	0.904356	90.44
2	empfaengerid + jahr → anschrift	0.954366	95.44
3	name + anschrift → empfaengerid	0.999500	99.95
4	empfaengerid + name + jahr → anschrift	0.956384	95.64

Nach der Normalisierung und Standardisierung ist der Zusammenhang zwischen der Empfänger-ID und den zugehörigen Namen beziehungsweise Anschriften deutlich eindeutiger. Unterschiedliche Schreibweisen und formale Abweichungen wurden vereinheitlicht, sodass identische Organisationen zuverlässiger derselben Empfänger-ID zugeordnet werden können.

Textdaten erneut normalisieren

Die standardisierten Textspalten werden für die Modellierung zusätzlich in modellgeeignete Textspalten überführt. Dabei bleiben die fachlich standardisierten Werte unverändert erhalten. Die erneute Normalisierung dient nur dazu, oberflächliche Schreibvarianten, Groß- und Kleinschreibung, Sonderzeichen und uneinheitliche Leerzeichen für die Merkmalsextraktion zu reduzieren.

► Code

2.7. Logarithmische Transformation der numerischen Spalte **betrag**

Die Spalte **betrag** weist typischerweise eine rechtsschiefe Verteilung mit wenigen sehr hohen Förderbeträgen auf. Durch die Transformation $\log_{1p}(x) = \log(1 + x)$ werden große Werte komprimiert und der Einfluss extremer Beträge reduziert. Da bei dieser Transformation keine Parameter aus den Daten gelernt werden, kann sie vor der Aufteilung auf den gesamten Datensatz angewendet werden. Die ursprüngliche Spalte bleibt zur Nachvollziehbarkeit erhalten.

► Code

	betrag	betrag_standardised
0	1724	7.452982
1	4000	8.294300
2	4070	8.311644
3	4066	8.310661
4	464891	13.049560

2.8 Untersuchung einer kontextweisen Neuordnung der kleineren Klassen

Grundsätzlich wäre es möglich, sehr kleine Klassen anhand ihres inhaltlichen Kontexts einer übergeordneten oder größeren Klasse zuzuordnen. Da hierfür jedoch fachliche Informationen des offiziellen Datengebers fehlen, wäre eine rein automatische Umklassifizierung riskant und könnte die ursprüngliche Bedeutung der Zielvariable verfälschen. Daher wird keine automatische Zusammenlegung vorgenommen. Stattdessen wird lediglich explorativ geprüft, ob es zwischen seltenen und häufigeren Politikbereichen Hinweise auf inhaltliche Überschneidungen gibt.

► Code

	politikbereich	geber_standardised	name_standardised	zweck_standardised
703	Internationales	regierende bürgermeisterin/regierender bürgerm...	aff galerie e. v.	ausstellungsprojekt berlin-madrid

	politikbereich	geber_standardised	name_standardised	zweck_standardised
2172	Medien	bezirksamt treptow-köpenick	allende 2 hilft e. v.	verfügungsfonds "überarbeitung der homepage"
4028	Internationales	regierende bürgermeisterin/regierender bürgerm...	deutsch-russischer austausch e. v.	zivilgesellschaftsaustausch im rahmen der städ...
4093	Tierschutz	senatsverwaltung	avian vogelschutz-verein e. v.	bestandsreduz. auffangstat. f. gemeldete ta...
4094	Tierschutz	bezirksamt spandau	avian vogelschutz-verein e. v.	unterstützung des funktionierenden taubenschla...

► Code

	kleine_Klasse	groessere_Klasse	text_similarity	support_kleine_Klasse	support_groessere_Klasse
0	Internationales	Europa	0.4039	27	106
1	Medien	Europa	0.3299	19	106
2	Tierschutz	Verbraucherschutz	0.1754	9	201
3	Medien	Bürgerschaftliches Engagement, Bürgerbeteiligung	0.1665	19	1759
4	Berlin-Image	Europa	0.1605	5	106
5	Medien	Kultur	0.1325	19	4692
6	Internationales	Bürgerschaftliches Engagement, Bürgerbeteiligung	0.1281	27	1759
7	Tierschutz	Integration	0.1188	9	1722
8	Internationales	Kultur	0.1179	27	4692
9	Tierschutz	Antidiskriminierung	0.1037	9	844
10	Tierschutz	Justiz	0.1032	9	230
11	Tierschutz	Soziales	0.1026	9	2865
12	Internationales	Soziales	0.0973	27	2865
13	Internationales	Stadtentwicklung	0.0951	27	1360
14	Medien	Soziales	0.0901	19	2865
15	Medien	Stadtentwicklung	0.0877	19	1360
16	Finanzen	Denkmalschutz	0.0649	18	264
17	Finanzen	Integration	0.0589	18	1722
18	Finanzen	Kultur	0.0566	18	4692
19	Berlin-Image	Wissenschaft	0.0555	5	204
20	Finanzen	Soziales	0.0551	18	2865
21	Berlin-Image	Denkmalschutz	0.0537	5	264

	kleine_Klasse	groessere_Klasse	text_similarity	support_kleine_Klasse	support_groessere_Klasse
22	Berlin-Image	Kultur	0.0533	5	4692
23	Finanzen	Umwelt	0.0532	18	1150
24	Berlin-Image	Stadtentwicklung	0.0485	5	1360

Die explorative Ähnlichkeitsanalyse zeigt nur bei wenigen seltenen Klassen eine erkennbare Nähe zu größeren Politikbereichen. Am deutlichsten ist die Beziehung zwischen „Internationales“ und „Europa“. Dennoch kann daraus keine automatische Zusammenlegung abgeleitet werden, da eine textuelle Ähnlichkeit nicht zwingend eine fachliche Teilmengenbeziehung bedeutet. Besonders bei Klassen mit sehr geringer Fallzahl, wie „Berlin-Image“ oder „Tierschutz“, sind die Werte zudem instabil und stark von einzelnen Datensätzen abhängig. Daher werden die kleinen Klassen nicht automatisch umklassifiziert, sondern lediglich als Klassen mit geringer statistischer Belastbarkeit gekennzeichnet.

3. Speicherung der standardisierten Gesamtdaten

3.1. Speicherung der Gesamtdaten

Der bereinigte und standardisierte Gesamtdatensatz wird gespeichert, damit die nachfolgenden Notebooks für Datensplitting, Modellierung und Evaluation auf einer konsistenten Datenbasis aufbauen können.

► Code

Entfernte vollständig identische Datensätze: 69