

4. Train / Validation / Test Data

Code ▾

► Code

Der Split wird stratifiziert durchgeführt, damit die Klassenverteilung des `politikbereich` in Trainings- und Testdaten möglichst stabil bleibt. Das ist wichtig, weil mehrere Politikbereiche nur wenige Beobachtungen enthalten. Der Testdatensatz bleibt anschließend unberührt und wird erst in der finalen Evaluation verwendet.

Aufgrund der stark ungleichen Klassenverteilung wird kein separates Validierungsset gebildet. Besonders seltene Klassen würden dadurch weiter aufgeteilt, wodurch die Bewertung einzelner Klassen instabil werden könnte. Stattdessen wird ein stratifizierter Train-Test-Split verwendet. Die Modellauswahl erfolgt ausschließlich auf dem Trainingsdatensatz mittels Stratified K-Fold Cross-Validation. Der Testdatensatz bleibt bis zur finalen Evaluation unberührt.

Zusätzlich wurde geprüft, ob ein Oversampling der kleinen Klassen sinnvoll wäre. Für diesen Datensatz wird Oversampling jedoch nicht als Hauptstrategie verwendet. Einige Klassen enthalten nur sehr wenige Beobachtungen, sodass ein einfaches Oversampling vor allem dieselben Beispiele mehrfach wiederholen würde. Dadurch steigt das Risiko, dass das Modell einzelne seltene Textmuster auswendig lernt und die Modellleistung zu optimistisch eingeschätzt wird.

Stattdessen wird die Klassenverteilung über das Evaluationsdesign und die Modellparameter berücksichtigt. Die Modellbewertung erfolgt über stratifizierte Cross-Validation, Macro-F1, Balanced Accuracy und klassenbezogene Metriken. Zusätzlich werden Modelle mit `class_weight="balanced"` verwendet, sodass kleinere Klassen während des Trainings stärker berücksichtigt werden. Oversampling kann optional als separates Experiment geprüft werden, sollte dann aber ausschließlich innerhalb der Cross-Validation-Pipeline erfolgen, um Data Leakage zu vermeiden.

Ein Group-CV-Ansatz auf Basis der `empfaengerid_standardised` wäre grundsätzlich sinnvoll, obwohl die Empfänger-ID selbst nicht als Trainingsmerkmal verwendet wird. Der Grund ist, dass andere Merkmale wie `name_standardised` und `anschrift_standardised` stark mit der Empfänger-ID zusammenhängen können. Dadurch könnte das Modell indirekt empfängerspezifische Muster lernen, etwa wiederkehrende Kombinationen aus Organisation, Adresse und Politikbereich.

Für die Hauptmodellierung wird Group CV jedoch nicht verwendet. Der wichtigste Grund ist die sehr ungleiche Klassenverteilung: Einige Politikbereiche enthalten nur sehr wenige Beobachtungen. Durch eine zusätzliche Gruppierung nach Empfänger-ID könnten diese seltenen Klassen innerhalb einzelner Folds weiter ausgedünnt oder sogar vollständig fehlen. Dadurch würde die Bewertung einzelner Klassen instabiler und schwerer interpretierbar.

Daher wird in dieser Arbeit primär stratifizierte Cross-Validation verwendet, um die Klassenverteilung in den Folds möglichst stabil zu halten. Group CV bleibt methodisch eine sinnvolle Robustheitsprüfung, wird jedoch aus Zeit- und Umfangsgründen nicht zusätzlich umgesetzt. In einer weiterführenden Analyse könnte ein solcher Check verwendet werden, um mögliche empfängerspezifische Proxy-Effekte über Name und Anschrift genauer zu untersuchen.

► Code

	politikbereich	support	share_%	low_support
0	Wirtschaft	11348	19.77	False
1	Arbeit	7807	13.60	False
2	Sport	6041	10.52	False
3	Jugend	5996	10.45	False
4	Kultur	4692	8.17	False
5	Bildung	3372	5.87	False
6	Soziales	2860	4.98	False
7	Gesundheit	2824	4.92	False
8	Bürgerschaftliches Engagement, Bürgerbeteiligung	1756	3.06	False
9	Integration	1719	2.99	False
10	Stadtentwicklung	1359	2.37	False
11	Familie	1258	2.19	False
12	Umwelt	1150	2.00	False
13	Verkehr	1105	1.93	False
14	Antidiskriminierung	844	1.47	False
15	Gleichstellung	632	1.10	False
16	Pflege	549	0.96	False
17	Forschung	282	0.49	False
18	Denkmalschutz	264	0.46	False
19	Frauen	238	0.41	False
20	Justiz	230	0.40	False
21	Kirchen, Religions-, Weltanschauungsgemeinscha...	219	0.38	False
22	Wissenschaft	204	0.36	False
23	Verbraucherschutz	201	0.35	False
24	Sicherheit, Ordnung	162	0.28	False
25	Europa	106	0.18	False
26	Bauen, Wohnen	104	0.18	False
27	Internationales	27	0.05	True
28	Medien	19	0.03	True
29	Finanzen	18	0.03	True
30	Tierschutz	9	0.02	True
31	Berlin-Image	5	0.01	True

► Code

Train: (45920, 29)

Test: (11480, 29)

	Gesamt	Train	Test
politikbereich			
Wirtschaft	11348	9078	2270
Arbeit	7807	6246	1561
Sport	6041	4833	1208
Jugend	5996	4797	1199
Kultur	4692	3754	938
Bildung	3372	2698	674
Soziales	2860	2288	572
Gesundheit	2824	2259	565
Bürgerschaftliches Engagement, Bürgerbeteiligung	1756	1405	351
Integration	1719	1375	344
Stadtentwicklung	1359	1087	272
Familie	1258	1006	252
Umwelt	1150	920	230
Verkehr	1105	884	221
Antidiskriminierung	844	675	169
Gleichstellung	632	506	126
Pflege	549	439	110
Forschung	282	226	56
Denkmalschutz	264	211	53
Frauen	238	190	48
Justiz	230	184	46
Kirchen, Religions-, Weltanschauungsgemeinschaften	219	175	44
Wissenschaft	204	163	41
Verbraucherschutz	201	161	40
Sicherheit, Ordnung	162	130	32
Europa	106	85	21
Bauen, Wohnen	104	83	21
Internationales	27	22	5
Medien	19	15	4
Finanzen	18	14	4
Tierschutz	9	7	2

	Gesamt	Train	Test
politikbereich			
Berlin-Image	5	4	1

► Code