

6. Hyperparameteroptimierung der klassischen Modellen mit Optuna

</> Code ▾

In diesem Notebook werden die aussichtsreichsten klassischen Modelle aus der Baseline-Phase mit Optuna optimiert. Die Optimierung erfolgt ausschließlich auf dem Trainingsdatensatz. Der Testdatensatz bleibt weiterhin unberührt und wird erst in der finalen Evaluation verwendet.

6.1. Ziel der Optimierung

Die bisherigen Experimente zeigen, dass das Szenario `Text + categorical` eine gute Balance zwischen Modellleistung und reduzierter Merkmalskomplexität liefert. Daher wird dieses Szenario für die Hyperparameteroptimierung als feste Datengrundlage verwendet.

Die Reihenfolge der Optimierung orientiert sich an der bisherigen Laufzeit: Zuerst wird `SGDClassifier(loss="hinge")` optimiert, da dieses Modell sehr schnell trainiert und dadurch mehr Suchläufe erlaubt. Anschließend wird `Logistic Regression balanced` optimiert, da dieses Modell in der Baseline den höchsten Macro-F1-Score erzielt hat.

Als Hauptmetrik wird weiterhin `Macro-F1` verwendet. Zusätzlich werden Standardabweichung, Train-Test-Gap, Weighted-F1, Balanced Accuracy und Laufzeit dokumentiert, damit die Modellauswahl nicht nur auf einem einzelnen Mittelwert basiert.

► Code

6.2. Daten laden

Es werden nur die Trainingsdaten geladen. Die Hyperparameteroptimierung darf den Testdatensatz nicht verwenden, damit die finale Modellbewertung unverzerrt bleibt.

► Code

Trainingsdaten: (45920, 28)

	name	geber	art	jahr	anschrift	politikbereich	zweck	betrag	emj
id									
33655	Cashmere Radio e. V.	Senatsverwaltung für Kultur und Gesellschaftli...	Projektförderung	2024	Frankfurter Allee 7, 10247 Berlin	Kultur	signal2noise ? Art, Aesthetics And Social Prac...	120000	vr_(
105910	Merantix Labs GmbH	Senatsverwaltung für Wirtschaft, Energie und B...	Projektförderung	2022	Max-Urich-Straße 3, 13355 Berlin	Wirtschaft	Errichtung einer Betriebsstätte	5481380	hrb.

	name	geber	art	jahr	anschrift	politikbereich	zweck	betrag	emp
id									
67465	Georg-Kolbe-Stiftung	Senatsverwaltung für Kultur und Europa	Projektförderung	2020	Sensburger Allee 25, 14055 Berlin	Kultur	Der absolute Tanz- Festival sculpture	70000	spr_
159301	Verschiedene Gesellschaften bürgerlichen Rechts	Senatsverwaltung für Inneres, Digitalisierung ...	Projektförderung	2023	'---'	Sport	Kosten für die Beschäftigung von Übungsleitern	1380	NaM
19495	Berliner Rugby-Club	Senatsverwaltung für Inneres und Sport	Projektförderung	2020	Scharfestraße 12, 14169 Berlin	Sport	anteilige Finanzierung des Spielbetriebes der ...	9000	vr_

5 rows × 28 columns

6.3. Optimierungsszenario festlegen

Für das Tuning wird das Szenario **Text + categorical** verwendet. Numerische Merkmale werden in diesem Szenario bewusst nicht verwendet, da die Ablation darauf hindeutet, dass die Text- und kategorialen Merkmale für diese Aufgabe ausreichend stark sind.

► Code

Verwendete Eingabespalten:

Trainingsspalte	
0	name_standardised
1	geber_standardised
2	anschrift_standardised
3	zweck_standardised
4	art_standardised
5	jahr

Anzahl Klassen: 32

6.4. Vorverarbeitung und Evaluationsrahmen

Die Vorverarbeitung entspricht der Baseline-Logik: Jede Textspalte wird separat mit TF-IDF verarbeitet, kategoriale Merkmale werden One-Hot-codiert. Für die Bewertung wird Stratified K-Fold Cross-Validation verwendet, damit die Klassenverteilung in den Folds möglichst stabil bleibt.

► Code

6.5. Hilfsfunktionen für Optuna

Für jeden Trial wird eine Cross-Validation durchgeführt. Optuna maximiert den durchschnittlichen Test-Macro-F1-Score. Zusätzlich werden Train-Macro-F1, Generalization Gap, Standardabweichung und Laufzeit gespeichert, damit Overfitting und Stabilität beurteilt werden können.

► Code

6.6. Optuna und MLflow vorbereiten

Die Optuna-Studien werden in einer SQLite-Datei gespeichert. Dadurch können bereits berechnete Trials später wiederverwendet werden. Zusätzlich werden die besten Ergebnisse als CSV-Dateien gespeichert und in MLflow dokumentiert.

► Code

```
Optuna storage: sqlite:///d:/toydev/schwarz-test/data/processed/optuna_studies.db
MLflow tracking URI: file:///d:/toydev/schwarz-test/mlruns
```

6.7. Studie 1: SGDClassifier mit Hinge Loss

Zuerst wird das schnelle SGD-SVM-Modell optimiert. Der Schwerpunkt liegt auf der Regularisierung (`alpha`), der Penalty-Struktur und der Konvergenztoleranz. `class_weight="balanced"` bleibt gesetzt, weil die Zielvariable deutlich unausgewogen ist.

► Code

```
[I 2026-07-27 20:55:30,355] Trial 0 finished with value: 0.6747 and parameters: {'penalty':
'elasticnet', 'alpha': 0.000157029708840554, 'max_iter': 1000, 'tol': 0.001, 'average': False,
'l1_ratio': 0.48645943347289744}. Best is trial 0 with value: 0.6747.

[I 2026-07-27 20:55:54,644] Trial 1 finished with value: 0.8053 and parameters: {'penalty': 'l2',
'alpha': 3.5113563139704077e-06, 'max_iter': 5000, 'tol': 0.01, 'average': True}. Best is trial 1
with value: 0.8053.

[I 2026-07-27 20:56:20,004] Trial 2 finished with value: 0.0719 and parameters: {'penalty':
'elasticnet', 'alpha': 0.0002267398652378039, 'max_iter': 5000, 'tol': 0.001, 'average': True,
'l1_ratio': 0.4845344148835517}. Best is trial 1 with value: 0.8053.

[I 2026-07-27 20:56:43,094] Trial 3 finished with value: 0.8079 and parameters: {'penalty': 'l2',
'alpha': 1.9634341572933354e-06, 'max_iter': 1000, 'tol': 0.01, 'average': True}. Best is trial 3
with value: 0.8079.
```

[I 2026-07-27 20:57:15,163] Trial 4 finished with value: 0.8215 and parameters: {'penalty': 'elasticnet', 'alpha': 4.366473592979636e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.13819228808861533}. Best is trial 4 with value: 0.8215.

[I 2026-07-27 20:57:40,534] Trial 5 finished with value: 0.8102 and parameters: {'penalty': 'elasticnet', 'alpha': 1.4656553886225336e-05, 'max_iter': 2000, 'tol': 0.001, 'average': False, 'l1_ratio': 0.49409912147023277}. Best is trial 4 with value: 0.8215.

[I 2026-07-27 20:58:10,567] Trial 6 finished with value: 0.8207 and parameters: {'penalty': 'l2', 'alpha': 1.0388823104027941e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': True}. Best is trial 4 with value: 0.8215.

[I 2026-07-27 20:58:34,737] Trial 7 finished with value: 0.8181 and parameters: {'penalty': 'l2', 'alpha': 1.5512259126484753e-06, 'max_iter': 5000, 'tol': 0.001, 'average': True}. Best is trial 4 with value: 0.8215.

[I 2026-07-27 20:58:54,605] Trial 8 finished with value: 0.7989 and parameters: {'penalty': 'l2', 'alpha': 0.00020554245520150764, 'max_iter': 2000, 'tol': 0.001, 'average': False}. Best is trial 4 with value: 0.8215.

[I 2026-07-27 20:59:21,736] Trial 9 finished with value: 0.8277 and parameters: {'penalty': 'elasticnet', 'alpha': 5.595986878006084e-06, 'max_iter': 2000, 'tol': 0.001, 'average': False, 'l1_ratio': 0.33503169042969055}. Best is trial 9 with value: 0.8277.

[I 2026-07-27 20:59:54,811] Trial 10 finished with value: 0.8391 and parameters: {'penalty': 'elasticnet', 'alpha': 1.019932851577901e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.29342475867899653}. Best is trial 10 with value: 0.8391.

[I 2026-07-27 21:00:29,512] Trial 11 finished with value: 0.8412 and parameters: {'penalty': 'elasticnet', 'alpha': 9.464114674843985e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.2970177684661907}. Best is trial 11 with value: 0.8412.

[I 2026-07-27 21:01:04,901] Trial 12 finished with value: 0.837 and parameters: {'penalty': 'elasticnet', 'alpha': 1.8819519105571703e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.2780158623258376}. Best is trial 11 with value: 0.8412.

[I 2026-07-27 21:01:37,013] Trial 13 finished with value: 0.8116 and parameters: {'penalty': 'elasticnet', 'alpha': 5.748702434765382e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.1735182379771164}. Best is trial 11 with value: 0.8412.

[I 2026-07-27 21:02:00,977] Trial 14 finished with value: 0.4932 and parameters: {'penalty': 'elasticnet', 'alpha': 0.0007890122142467837, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.3478765981685176}. Best is trial 11 with value: 0.8412.

[I 2026-07-27 21:02:32,849] Trial 15 finished with value: 0.8363 and parameters: {'penalty': 'elasticnet', 'alpha': 6.917878430886958e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.21499156747541698}. Best is trial 11 with value: 0.8412.

[I 2026-07-27 21:03:08,039] Trial 16 finished with value: 0.8509 and parameters: {'penalty': 'elasticnet', 'alpha': 8.134650578175102e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.06630695965395372}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:03:43,505] Trial 17 finished with value: 0.8402 and parameters: {'penalty': 'elasticnet', 'alpha': 3.4578585803329408e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.052059391335030174}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:04:06,337] Trial 18 finished with value: 0.7988 and parameters: {'penalty': 'elasticnet', 'alpha': 2.5382651243142182e-05, 'max_iter': 5000, 'tol': 0.01, 'average': False, 'l1_ratio': 0.3996433004044841}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:04:40,755] Trial 19 finished with value: 0.8129 and parameters: {'penalty': 'elasticnet', 'alpha': 8.28715379790703e-05, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.059668087363515566}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:05:15,990] Trial 20 finished with value: 0.8336 and parameters: {'penalty': 'elasticnet', 'alpha': 1.0584011055150882e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.22117580682877092}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:05:47,212] Trial 21 finished with value: 0.8372 and parameters: {'penalty': 'elasticnet', 'alpha': 3.6551272909167294e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.05612897890417276}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:06:21,504] Trial 22 finished with value: 0.844 and parameters: {'penalty': 'elasticnet', 'alpha': 3.6664753175857784e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.1073898605398526}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:06:56,692] Trial 23 finished with value: 0.8396 and parameters: {'penalty': 'elasticnet', 'alpha': 6.562591066071081e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.13642087521211016}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:07:35,899] Trial 24 finished with value: 0.8408 and parameters: {'penalty': 'elasticnet', 'alpha': 2.0889683476765056e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.11966549659828606}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:07:59,092] Trial 25 finished with value: 0.8105 and parameters: {'penalty': 'elasticnet', 'alpha': 1.4450650491648738e-05, 'max_iter': 2000, 'tol': 0.01, 'average': False, 'l1_ratio': 0.22341304016574592}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:08:33,466] Trial 26 finished with value: 0.817 and parameters: {'penalty': 'l2', 'alpha': 5.044122616050271e-06, 'max_iter': 2000, 'tol': 0.0001, 'average': True}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:09:12,974] Trial 27 finished with value: 0.8339 and parameters: {'penalty': 'elasticnet', 'alpha': 2.9407880593658378e-05, 'max_iter': 2000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.09755196847688313}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:09:54,215] Trial 28 finished with value: 0.8398 and parameters: {'penalty': 'elasticnet', 'alpha': 9.510455496349715e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.17637226880282186}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:10:20,954] Trial 29 finished with value: 0.8248 and parameters: {'penalty': 'elasticnet', 'alpha': 2.6469851532204823e-06, 'max_iter': 5000, 'tol': 0.01, 'average': False, 'l1_ratio': 0.41471068504334035}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:10:56,487] Trial 30 finished with value: 0.8428 and parameters: {'penalty': 'elasticnet', 'alpha': 1.1348451194974601e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.09039874458455135}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:11:31,632] Trial 31 finished with value: 0.8407 and parameters: {'penalty': 'elasticnet', 'alpha': 1.0344863915818467e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.09203559777476}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:12:09,429] Trial 32 finished with value: 0.8346 and parameters: {'penalty': 'elasticnet', 'alpha': 1.4862903029938664e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.17594054569216636}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:12:43,295] Trial 33 finished with value: 0.845 and parameters: {'penalty': 'elasticnet', 'alpha': 3.850139044221971e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.08729629796684804}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:13:17,079] Trial 34 finished with value: 0.8171 and parameters: {'penalty': 'l2', 'alpha': 4.004360502566311e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': True}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:13:42,068] Trial 35 finished with value: 0.8267 and parameters: {'penalty': 'elasticnet', 'alpha': 2.2569304624146846e-06, 'max_iter': 1000, 'tol': 0.01, 'average': False, 'l1_ratio': 0.09500064142533551}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:14:28,216] Trial 36 finished with value: 0.8114 and parameters: {'penalty': 'elasticnet', 'alpha': 3.0032557560093967e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': True, 'l1_ratio': 0.09594032859025545}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:14:58,942] Trial 37 finished with value: 0.83 and parameters: {'penalty': 'elasticnet', 'alpha': 1.487629812744681e-06, 'max_iter': 1000, 'tol': 0.001, 'average': False, 'l1_ratio': 0.14505232347978725}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:15:30,118] Trial 38 finished with value: 0.8192 and parameters: {'penalty': 'l2', 'alpha': 4.36481061870459e-06, 'max_iter': 1000, 'tol': 0.0001, 'average': True}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:16:05,443] Trial 39 finished with value: 0.8414 and parameters: {'penalty': 'elasticnet', 'alpha': 1.7321149166216345e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.0748984099358816}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:16:28,751] Trial 40 finished with value: 0.8308 and parameters: {'penalty': 'l2', 'alpha': 1.0741014847253049e-06, 'max_iter': 1000, 'tol': 0.001, 'average': False}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:17:03,170] Trial 41 finished with value: 0.8451 and parameters: {'penalty': 'elasticnet', 'alpha': 1.8766916970643716e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.07657409712100584}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:17:36,132] Trial 42 finished with value: 0.8478 and parameters: {'penalty': 'elasticnet', 'alpha': 2.4408427745666938e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.11579523915809711}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:18:11,492] Trial 43 finished with value: 0.8409 and parameters: {'penalty': 'elasticnet', 'alpha': 2.6193272558713546e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.11067607303641375}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:18:44,649] Trial 44 finished with value: 0.8395 and parameters: {'penalty': 'elasticnet', 'alpha': 6.869749717255972e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.1271604143576524}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:19:21,104] Trial 45 finished with value: 0.8396 and parameters: {'penalty': 'elasticnet', 'alpha': 5.252085254986975e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.14881331115287677}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:19:57,594] Trial 46 finished with value: 0.8143 and parameters: {'penalty': 'elasticnet', 'alpha': 1.8507926595819011e-06, 'max_iter': 5000, 'tol': 0.001, 'average': True, 'l1_ratio': 0.07752977176068694}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:20:25,341] Trial 47 finished with value: 0.561 and parameters: {'penalty': 'elasticnet', 'alpha': 0.0007058882123454629, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.1598882198042698}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:20:47,238] Trial 48 finished with value: 0.8226 and parameters: {'penalty': 'l2', 'alpha': 1.6228609790975253e-05, 'max_iter': 5000, 'tol': 0.01, 'average': False}. Best is trial 16 with value: 0.8509.

[I 2026-07-27 21:21:25,318] Trial 49 finished with value: 0.8326 and parameters: {'penalty': 'elasticnet', 'alpha': 3.1569492884255573e-06, 'max_iter': 5000, 'tol': 0.0001, 'average': False, 'l1_ratio': 0.19567752043574008}. Best is trial 16 with value: 0.8509.

	Modell	trial_number	objective_value	penalty	alpha	max_iter	tol	average	l1_ratio	accuracy_mean	...	train
0	SGD hinge	16	0.8509	elasticnet	0.000008	2000	0.0001	False	0.066307	0.9410	...	0.99
1	SGD hinge	42	0.8478	elasticnet	0.000002	5000	0.0001	False	0.115795	0.9389	...	0.99
2	SGD hinge	41	0.8451	elasticnet	0.000002	5000	0.0001	False	0.076574	0.9375	...	0.99
3	SGD hinge	33	0.8450	elasticnet	0.000004	1000	0.0001	False	0.087296	0.9387	...	0.99
4	SGD hinge	22	0.8440	elasticnet	0.000004	2000	0.0001	False	0.107390	0.9395	...	0.99
5	SGD hinge	30	0.8428	elasticnet	0.000001	1000	0.0001	False	0.090399	0.9361	...	0.99
6	SGD hinge	39	0.8414	elasticnet	0.000002	5000	0.0001	False	0.074898	0.9378	...	0.99
7	SGD hinge	11	0.8412	elasticnet	0.000009	2000	0.0001	False	0.297018	0.9391	...	0.99

	Modell	trial_number	objective_value	penalty	alpha	max_iter	tol	average	l1_ratio	accuracy_mean	...	train
8	SGD hinge	43	0.8409	elasticnet	0.000003	5000	0.0001	False	0.110676	0.9371	...	0.99
9	SGD hinge	24	0.8408	elasticnet	0.000002	2000	0.0001	False	0.119665	0.9370	...	0.99

10 rows × 41 columns

6.8. Studie 2: Logistische Regression (Aufgrund der Zeitaufwand noch nicht ausgeführt)

Anschließend wird die reguläre logistische Regression optimiert. Dieses Modell war in der Baseline sehr stark, ist aber rechenintensiver als das SGD-Modell. Deshalb wird es nach dem schnellen SGD-Modell optimiert.

► Code

6.9. Ergebnisse vergleichen und speichern

Zum Abschluss werden die besten Trials beider Studien zusammengeführt. Für die finale Auswahl werden nicht nur Macro-F1, sondern auch Standardabweichung, Generalization Gap und Laufzeit betrachtet.

► Code

	Modell	trial_number	objective_value	penalty	alpha	max_iter	tol	average	l1_ratio	accuracy_mean	...	train
0	SGD hinge	16	0.8509	elasticnet	0.000008	2000	0.0001	False	0.066307	0.9410	...	0.99
1	SGD hinge	42	0.8478	elasticnet	0.000002	5000	0.0001	False	0.115795	0.9389	...	0.99
2	SGD hinge	41	0.8451	elasticnet	0.000002	5000	0.0001	False	0.076574	0.9375	...	0.99
3	SGD hinge	33	0.8450	elasticnet	0.000004	1000	0.0001	False	0.087296	0.9387	...	0.99
4	SGD hinge	22	0.8440	elasticnet	0.000004	2000	0.0001	False	0.107390	0.9395	...	0.99
5	SGD hinge	30	0.8428	elasticnet	0.000001	1000	0.0001	False	0.090399	0.9361	...	0.99
6	SGD hinge	39	0.8414	elasticnet	0.000002	5000	0.0001	False	0.074898	0.9378	...	0.99
7	SGD hinge	11	0.8412	elasticnet	0.000009	2000	0.0001	False	0.297018	0.9391	...	0.99

	Modell	trial_number	objective_value	penalty	alpha	max_iter	tol	average	l1_ratio	accuracy_mean	...	tr
8	SGD hinge	43	0.8409	elasticnet	0.000003	5000	0.0001	False	0.110676	0.9371	...	0.9
9	SGD hinge	24	0.8408	elasticnet	0.000002	2000	0.0001	False	0.119665	0.9370	...	0.9
10	SGD hinge	31	0.8407	elasticnet	0.000001	1000	0.0001	False	0.092036	0.9358	...	0.9
11	SGD hinge	17	0.8402	elasticnet	0.000003	2000	0.0001	False	0.052059	0.9381	...	0.9
12	SGD hinge	28	0.8398	elasticnet	0.000010	1000	0.0001	False	0.176372	0.9399	...	0.9
13	SGD hinge	23	0.8396	elasticnet	0.000007	2000	0.0001	False	0.136421	0.9395	...	0.9
14	SGD hinge	45	0.8396	elasticnet	0.000005	5000	0.0001	False	0.148813	0.9392	...	0.9
15	SGD hinge	44	0.8395	elasticnet	0.000007	5000	0.0001	False	0.127160	0.9403	...	0.9
16	SGD hinge	10	0.8391	elasticnet	0.000010	2000	0.0001	False	0.293425	0.9383	...	0.9
17	SGD hinge	21	0.8372	elasticnet	0.000004	2000	0.0001	False	0.056129	0.9382	...	0.9
18	SGD hinge	12	0.8370	elasticnet	0.000019	2000	0.0001	False	0.278016	0.9348	...	0.9
19	SGD hinge	15	0.8363	elasticnet	0.000007	2000	0.0001	False	0.214992	0.9399	...	0.9

20 rows × 40 columns

Gespeichert: d:\toydev\schwarz-test\data\processed\optuna_tuning_results.csv

Gespeichert: d:\toydev\schwarz-test\data\processed\optuna_sgd_hinge_results.csv

Gespeichert: d:\toydev\schwarz-test\data\processed\optuna_logreg_results.csv

Die Optuna-Ergebnisse zeigen, ob sich die schnellen linearen Modelle durch gezielte Hyperparameterwahl weiter verbessern lassen. Diese Werte stammen aus Cross-Validation bzw. interner Validierung auf den Trainingsdaten und dienen der Modellauswahl. Die endgültige Aussage zur Generalisierung erfolgt erst im separaten Testdatensatz.

6.10. Bestes Modell für die finale Evaluation auswählen

Der beste Trial nach Macro-F1 ist ein erster Kandidat für die finale Evaluation. Vor der endgültigen Auswahl sollten jedoch auch `generalization_gap_macro_f1`, `macro_f1_std` und die Laufzeit betrachtet werden. Ein sehr hoher Train-Test-Gap kann auf Overfitting hinweisen.

► Code

Bestes Modell: SGD hinge

Trial: 16

Macro-F1: 0.8509

Generalization Gap Macro-F1: 0.1184

	Wert
Modell	SGD hinge
trial_number	16
objective_value	0.8509
penalty	elasticnet
alpha	0.000008
max_iter	2000
tol	0.0001
average	False
l1_ratio	0.066307
accuracy_mean	0.941
accuracy_std	0.0026
balanced_accuracy_mean	0.8562
balanced_accuracy_std	0.0088
fit_time_mean_seconds	5.29
fit_time_total_seconds	21.15
generalization_gap_accuracy	0.052
generalization_gap_balanced_accuracy	0.1346
generalization_gap_macro_f1	0.1184
generalization_gap_weighted_f1	0.0519
macro_f1_mean	0.8509
macro_f1_std	0.0053
model_name	SGD hinge
score_time_mean_seconds	0.94
test_accuracy_mean	0.941
test_accuracy_std	0.0026
test_balanced_accuracy_mean	0.8562
test_balanced_accuracy_std	0.0088
test_macro_f1_mean	0.8509
test_macro_f1_std	0.0053

	Wert
test_weighted_f1_mean	0.9412
test_weighted_f1_std	0.0023
train_accuracy_mean	0.993
train_accuracy_std	0.0003
train_balanced_accuracy_mean	0.9908
train_balanced_accuracy_std	0.0023
train_macro_f1_mean	0.9693
train_macro_f1_std	0.0069
train_weighted_f1_mean	0.9931
train_weighted_f1_std	0.0003
weighted_f1_mean	0.9412
weighted_f1_std	0.0023

Gespeichertes finales Optuna-Modell: d:\toydev\schwarz-test\models\optuna\best_optuna_sgd_hinge.joblib

7. Hyperparameteroptimierung der neuen Modelle

Nach den klassischen scikit-learn-Modellen werden auch die beiden erweiterten NLP-Modelle `fastText` und BERT für eine Hyperparameteroptimierung vorbereitet. Diese Modelle verwenden keine `ColumnTransformer`-Pipeline. Stattdessen werden die verwendeten Spalten zuerst zu einem gemeinsamen Textfeld zusammengeführt.

Die Optimierung erfolgt weiterhin nur auf den Trainingsdaten. Zur Bewertung wird innerhalb der Trainingsdaten ein stratifizierter Validierungssplit verwendet. Der finale Testdatensatz bleibt unverändert unberührt.

7.1. Gemeinsame Textbasis für fastText und BERT

`fastText` und BERT erwarten jeweils einen zusammenhängenden Text pro Beobachtung. Deshalb werden die zuvor ausgewählten Text- und kategorialen Spalten zu einem markierten Text zusammengeführt. Die Feldnamen bleiben erhalten, damit Informationen wie `name`, `geber`, `zweck`, `art` und `jahr` nicht vollständig vermischt werden.

► Code

Verwendete Spalten für neue NLP-Modelle:

	Trainingsspalte
0	name_standardised
1	geber_standardised
2	anschrift_standardised
3	zweck_standardised

Trainingsspalte	
4	art_standardised
5	jahr

Trainingssplit: 41328
Validierungssplit: 4592

model_text	
id	
33655	name: cashmere radio e. v. geber: senatsverwal...
105910	name: merantix labs gmbh geber: senatsverwal...
67465	name: georg kolbe-stiftung geber: senatsverwal...

7.2. fastText mit Optuna optimieren

fastText ist schnell genug, um mehrere Hyperparameterkombinationen auszuprobieren. Optimiert werden unter anderem Lernrate, Anzahl der Epochen, Wort-n-Gramme, Zeichen-n-Gramme und die Einbettungsdimension. Als Zielwert wird wie zuvor der Macro-F1-Score auf dem internen Validierungssplit verwendet.

► Code

```
[I 2026-07-27 21:39:39,069] Trial 0 finished with value: 0.7361235503014153 and parameters:
{'epoch': 18, 'lr': 0.8627358286640178, 'wordNgrams': 3, 'dim': 50, 'minn': 2, 'loss': 'softmax',
'maxn': 7}. Best is trial 0 with value: 0.7361235503014153.
```

```
[I 2026-07-27 21:41:18,408] Trial 1 finished with value: 0.5114159838543018 and parameters:
{'epoch': 34, 'lr': 0.09445600138094695, 'wordNgrams': 1, 'dim': 200, 'minn': 3, 'loss': 'ova',
'maxn': 5}. Best is trial 0 with value: 0.7361235503014153.
```

```
[I 2026-07-27 21:41:29,955] Trial 2 finished with value: 0.8110745229611561 and parameters:
{'epoch': 21, 'lr': 0.5254210669345882, 'wordNgrams': 1, 'dim': 100, 'minn': 0, 'loss': 'ova'}.
Best is trial 2 with value: 0.8110745229611561.
```

```
[I 2026-07-27 21:42:10,227] Trial 3 finished with value: 0.5659551139768939 and parameters:
{'epoch': 34, 'lr': 0.12453219846912196, 'wordNgrams': 1, 'dim': 50, 'minn': 3, 'loss': 'ova',
'maxn': 5}. Best is trial 2 with value: 0.8110745229611561.
```

```
[I 2026-07-27 21:42:31,068] Trial 4 finished with value: 0.667462033864886 and parameters:
{'epoch': 23, 'lr': 0.25719142025384634, 'wordNgrams': 1, 'dim': 50, 'minn': 3, 'loss': 'ova',
'maxn': 4}. Best is trial 2 with value: 0.8110745229611561.
```

```
[I 2026-07-27 21:42:55,293] Trial 5 finished with value: 0.4414518212385496 and parameters:
{'epoch': 16, 'lr': 0.1601956861146523, 'wordNgrams': 1, 'dim': 50, 'minn': 3, 'loss': 'ova',
'maxn': 7}. Best is trial 2 with value: 0.8110745229611561.
```

```
[I 2026-07-27 21:43:50,587] Trial 6 finished with value: 0.19366511944714102 and parameters:
{'epoch': 12, 'lr': 0.05083401870011434, 'wordNgrams': 3, 'dim': 200, 'minn': 2, 'loss':
```

'softmax', 'maxn': 5}. Best is trial 2 with value: 0.8110745229611561.

[I 2026-07-27 21:44:27,895] Trial 7 finished with value: 0.2620449604583066 and parameters: {'epoch': 7, 'lr': 0.12693089228250282, 'wordNgrams': 1, 'dim': 200, 'minn': 3, 'loss': 'softmax', 'maxn': 7}. Best is trial 2 with value: 0.8110745229611561.

[I 2026-07-27 21:44:41,900] Trial 8 finished with value: 0.7808903246520628 and parameters: {'epoch': 22, 'lr': 0.23936524636621914, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 2 with value: 0.8110745229611561.

[I 2026-07-27 21:44:53,840] Trial 9 finished with value: 0.8016159915015668 and parameters: {'epoch': 19, 'lr': 0.48080026552717275, 'wordNgrams': 1, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 2 with value: 0.8110745229611561.

[I 2026-07-27 21:45:09,481] Trial 10 finished with value: 0.7885919508994462 and parameters: {'epoch': 26, 'lr': 0.49399671534451434, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'ova'}. Best is trial 2 with value: 0.8110745229611561.

[I 2026-07-27 21:45:26,088] Trial 11 finished with value: 0.8147132232957375 and parameters: {'epoch': 27, 'lr': 0.46885389069807476, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 11 with value: 0.8147132232957375.

[I 2026-07-27 21:45:43,588] Trial 12 finished with value: 0.8131158990908638 and parameters: {'epoch': 28, 'lr': 0.45359996216326987, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 11 with value: 0.8147132232957375.

[I 2026-07-27 21:46:02,511] Trial 13 finished with value: 0.8150819169874137 and parameters: {'epoch': 29, 'lr': 0.819330785442295, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 13 with value: 0.8150819169874137.

[I 2026-07-27 21:46:25,368] Trial 14 finished with value: 0.8011344274776412 and parameters: {'epoch': 39, 'lr': 0.9813887830525404, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 13 with value: 0.8150819169874137.

[I 2026-07-27 21:46:44,752] Trial 15 finished with value: 0.817482007134161 and parameters: {'epoch': 31, 'lr': 0.7223804090846411, 'wordNgrams': 2, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 15 with value: 0.817482007134161.

[I 2026-07-27 21:47:06,213] Trial 16 finished with value: 0.815213717880879 and parameters: {'epoch': 31, 'lr': 0.7723859278437772, 'wordNgrams': 3, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 15 with value: 0.817482007134161.

[I 2026-07-27 21:48:16,673] Trial 17 finished with value: 0.721034306415695 and parameters: {'epoch': 33, 'lr': 0.3296255904532606, 'wordNgrams': 3, 'dim': 100, 'minn': 2, 'loss': 'softmax', 'maxn': 4}. Best is trial 15 with value: 0.817482007134161.

[I 2026-07-27 21:48:41,449] Trial 18 finished with value: 0.8156670533241877 and parameters: {'epoch': 38, 'lr': 0.6553070558283778, 'wordNgrams': 3, 'dim': 100, 'minn': 0, 'loss': 'softmax'}. Best is trial 15 with value: 0.817482007134161.

[I 2026-07-27 21:49:14,843] Trial 19 finished with value: 0.8181848946121342 and parameters: {'epoch': 37, 'lr': 0.6352379868617901, 'wordNgrams': 3, 'dim': 200, 'minn': 0, 'loss': 'softmax'}. Best is trial 19 with value: 0.8181848946121342.

[I 2026-07-27 21:52:46,080] Trial 20 finished with value: 0.7362758952557998 and parameters: {'epoch': 40, 'lr': 0.3399860176167752, 'wordNgrams': 3, 'dim': 200, 'minn': 2, 'loss': 'softmax', 'maxn': 6}. Best is trial 19 with value: 0.8181848946121342.

[I 2026-07-27 21:53:19,130] Trial 21 finished with value: 0.816970749080655 and parameters: {'epoch': 37, 'lr': 0.6418516729235622, 'wordNgrams': 3, 'dim': 200, 'minn': 0, 'loss': 'softmax'}. Best is trial 19 with value: 0.8181848946121342.

[I 2026-07-27 21:53:55,190] Trial 22 finished with value: 0.8077290667596201 and parameters: {'epoch': 36, 'lr': 0.6630411051417688, 'wordNgrams': 3, 'dim': 200, 'minn': 0, 'loss': 'softmax'}. Best is trial 19 with value: 0.8181848946121342.

[I 2026-07-27 21:54:28,690] Trial 23 finished with value: 0.8176070033696257 and parameters: {'epoch': 36, 'lr': 0.6226184609656309, 'wordNgrams': 3, 'dim': 200, 'minn': 0, 'loss': 'softmax'}. Best is trial 19 with value: 0.8181848946121342.

[I 2026-07-27 21:54:54,569] Trial 24 finished with value: 0.8151256890492379 and parameters: {'epoch': 31, 'lr': 0.33269105289670226, 'wordNgrams': 2, 'dim': 200, 'minn': 0, 'loss': 'softmax'}. Best is trial 19 with value: 0.8181848946121342.

Bestes fastText-Modell gespeichert: d:\toydev\schwarz-test\models\optuna\new_nlp_models\fasttext\best_fasttext_politikbereich.bin

	Modell	trial_number	objective_value	epoch	lr	wordNgrams	dim	minn	loss	maxn	accuracy	balanced_a
0	fastText	19	0.818185	37	0.635238	3	200	0	softmax	NaN	0.938153	0.804543
1	fastText	23	0.817607	36	0.622618	3	200	0	softmax	NaN	0.938807	0.800787
2	fastText	15	0.817482	31	0.722380	2	100	0	softmax	NaN	0.939024	0.803813
3	fastText	21	0.816971	37	0.641852	3	200	0	softmax	NaN	0.937500	0.800961
4	fastText	18	0.815667	38	0.655307	3	100	0	softmax	NaN	0.937500	0.798312
5	fastText	16	0.815214	31	0.772386	3	100	0	softmax	NaN	0.937064	0.798791
6	fastText	24	0.815126	31	0.332691	2	200	0	softmax	NaN	0.937936	0.801873
7	fastText	13	0.815082	29	0.819331	2	100	0	softmax	NaN	0.936847	0.800705
8	fastText	11	0.814713	27	0.468854	2	100	0	softmax	NaN	0.937718	0.801136
9	fastText	12	0.813116	28	0.453600	2	100	0	softmax	NaN	0.936847	0.799917

7.3. BERT mit Optuna vorbereiten

BERT kann ebenfalls optimiert werden, ist aber deutlich rechenintensiver. Deshalb ist die BERT-Optimierung standardmäßig deaktiviert. In Colab mit GPU kann `run_bert_tuning = True` gesetzt werden. Optimiert werden nur wenige zentrale Parameter: Lernrate, Batch Size, Weight Decay, maximale Sequenzlänge und Anzahl der Epochen.

7.4. Ergebnisse der neuen Modelle zusammenführen

Die Ergebnisse der neuen NLP-Modelle werden separat gespeichert. Dadurch bleiben die klassischen Optuna-Ergebnisse reproduzierbar, während fastText und BERT als erweiterte Vergleichsmodelle ausgewertet werden können.

Gespeichert: d:\toydev\schwarz-test\data\processed\optuna_extended_nlp_results.csv

	Modell	trial_number	objective_value	epoch	lr	wordNgrams	dim	minn	loss	maxn	accuracy	balanced
0	fastText	19	0.818185	37	0.635238	3	200	0	softmax	NaN	0.938153	0.804543
1	fastText	23	0.817607	36	0.622618	3	200	0	softmax	NaN	0.938807	0.800787
2	fastText	15	0.817482	31	0.722380	2	100	0	softmax	NaN	0.939024	0.803813
3	fastText	21	0.816971	37	0.641852	3	200	0	softmax	NaN	0.937500	0.800961
4	fastText	18	0.815667	38	0.655307	3	100	0	softmax	NaN	0.937500	0.798312
5	fastText	16	0.815214	31	0.772386	3	100	0	softmax	NaN	0.937064	0.798791
6	fastText	24	0.815126	31	0.332691	2	200	0	softmax	NaN	0.937936	0.801873
7	fastText	13	0.815082	29	0.819331	2	100	0	softmax	NaN	0.936847	0.800705
8	fastText	11	0.814713	27	0.468854	2	100	0	softmax	NaN	0.937718	0.801136
9	fastText	12	0.813116	28	0.453600	2	100	0	softmax	NaN	0.936847	0.799917
10	fastText	2	0.811075	21	0.525421	1	100	0	ova	NaN	0.937936	0.797439
11	fastText	22	0.807729	36	0.663041	3	200	0	softmax	NaN	0.936629	0.786640
12	fastText	9	0.801616	19	0.480800	1	100	0	softmax	NaN	0.934887	0.790950
13	fastText	14	0.801134	39	0.981389	2	100	0	softmax	NaN	0.936847	0.782730
14	fastText	10	0.788592	26	0.493997	2	100	0	ova	NaN	0.941855	0.797841
15	fastText	8	0.780890	22	0.239365	2	100	0	softmax	NaN	0.935758	0.758629
16	fastText	20	0.736276	40	0.339986	3	200	2	softmax	6.0	0.933580	0.712356
17	fastText	0	0.736124	18	0.862736	3	50	2	softmax	7.0	0.933145	0.712182
18	fastText	17	0.721034	33	0.329626	3	100	2	softmax	4.0	0.929225	0.696630
19	fastText	4	0.667462	23	0.257191	1	50	3	ova	4.0	0.920296	0.638235

Die erweiterten NLP-Ergebnisse werden separat zusammengeführt, weil fastText und BERT nicht dieselbe scikit-learn-Pipeline verwenden. fastText kann mit begrenzter Rechenzeit relativ schnell getestet werden. BERT bleibt dagegen optional, da ein systematisches Fine-Tuning deutlich höhere GPU-Ressourcen erfordert.