

8. Finale Evaluation auf dem Testdatensatz

</> Code ▾

In diesem Notebook werden die bisher besten Modellkandidaten zusammengefasst und auf dem zuvor zurückgehaltenen Testdatensatz evaluiert. Der Testdatensatz wurde in den vorherigen Notebooks nicht für Modellwahl, Hyperparameteroptimierung oder Feature-Entscheidungen verwendet. Dadurch dient diese Auswertung als finale, unverzerrte Leistungsprüfung.

8.1. Ziel der finalen Evaluation

Die finale Evaluation verfolgt drei Ziele:

- 1. Die bisher gespeicherten Modellkandidaten werden automatisch gefunden.
- 2. Die wichtigsten Validierungs- und Cross-Validation-Ergebnisse werden als Übersicht zusammengeführt.
- 3. Alle verfügbaren gespeicherten Modelle werden auf denselben Testdaten bewertet.

Als Hauptmetrik bleibt `Macro-F1` relevant, weil die Zielvariable `politikbereich` deutlich unausgewogen ist. Zusätzlich werden Weighted-F1, Balanced Accuracy, Accuracy, Metriken pro Klasse und Konfusionsmatrizen betrachtet.

► Code

```
Projektverzeichnis: d:\toydev\schwarz-test
Report-Verzeichnis: d:\toydev\schwarz-test\reports\final_evaluation
```

8.2. Testdaten laden

Für die finale Evaluation wird ausschließlich `test_data.csv` verwendet. Die Trainingsdaten werden hier nicht erneut zur Modellwahl verwendet. Sie können lediglich als Referenz für Spaltennamen oder Klassenabdeckung dienen.

► Code

```
Testdaten: (11480, 28)
Anzahl Klassen im Testdatensatz: 32
```

	name	geber	art	jahr	anschrift	politikbereich	zweck	b
id								
77932	IBEB Initiative für Bildung und Erziehung Berl...	Senatsverwaltung für Bildung, Jugend und Familie	Projektförderung	2021	Wilhelmstraße 25-30, 13593 Berlin	Bildung	DigitalPakt Schule, SifT, ZV I - Sofortausstat...	7
40720	Denk mal an Berlin e. V.	Senatsverwaltung für	Projektförderung	2024	Kantstraße 106 , 10627 Berlin	Bürgerschaftliches Engagement, Bürgerbeteiligung	werkstatt denkmal 2024	2

	name	geber	art	jahr	anschrift	politikbereich	zweck	b
id								
		Stadtentwicklung, Bauen u...						
124984	Regionale Arbeitsstellen für Bildung, Integrat...	Senatsverwaltung für Integration, Arbeit und S...	Projektförderung	2021	Boyenstraße\n 41, 10115 Berlin	Integration	Mehrsprachige Beratung und Vermittlung im Schu...	5
10507	Artikel 1 - Initiative für Menschenwürde e. V.	Bezirksamt Mitte	Projektförderung	2022	Schlüterstraße 42, 10707 Berlin	Stadtentwicklung	FF Radikal Respektvoll II	8
129994	Schulstiftung der Evangelischen Kirche Berlin-...	Senatsverwaltung für Bildung, Jugend und Familie	Projektförderung	2022	Georgenkirchstraße 69/70 , 10249 Berlin	Bildung	DigitalPakt Schule, SifT, ZV I - Sofortausstat...	8

5 rows × 28 columns

	politikbereich	test_support
0	Wirtschaft	2270
1	Arbeit	1561
2	Sport	1208
3	Jugend	1199
4	Kultur	938
5	Bildung	674
6	Soziales	572
7	Gesundheit	565
8	Bürgerschaftliches Engagement, Bürgerbeteiligung	351
9	Integration	344
10	Stadtentwicklung	272
11	Familie	252
12	Umwelt	230
13	Verkehr	221
14	Antidiskriminierung	169
15	Gleichstellung	126
16	Pflege	110
17	Forschung	56
18	Denkmalschutz	53

	politikbereich	test_support
19	Frauen	48
20	Justiz	46
21	Kirchen, Religions-, Weltanschauungsgemeinscha...	44
22	Wissenschaft	41
23	Verbraucherschutz	40
24	Sicherheit, Ordnung	32
25	Europa	21
26	Bauen, Wohnen	21
27	Internationales	5
28	Medien	4
29	Finanzen	4
30	Tierschutz	2
31	Berlin-Image	1

8.3. Bisherige Modellkandidaten zusammenfassen

Die folgende Übersicht sammelt die bereits gespeicherten Ergebnisse aus Baseline, Ablation, Optuna und erweiterten NLP-Modellen. Die Tabelle dient nur zur Orientierung. Die finale Entscheidung wird anschließend anhand der Testdaten getroffen.

► Code

	Quelle	Scoretyp	Modell	Experiment	Macro-F1	Macro-F1 Std	Weighted F1
0	Optuna klassische Modelle	Validierung/CV während Tuning	SGD hinge	Validierung/CV während Tuning	0.8509	0.0053	0.9412
1	Baseline Cross-Validation	Cross-Validation	Logistic Regression balanced	Cross-Validation	0.8246	0.006	0.9068
2	Baseline Cross-Validation	Cross-Validation	Linear SVC unweighted	Cross-Validation	0.8225	0.0167	0.9266
3	Optuna neue NLP-Modelle	Validierung während Tuning	fastText	Validierung während Tuning	0.8182	-	0.9379
4	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Text + categorical	0.817	0.0132	0.9229
5	Baseline Cross-Validation	Cross-Validation	Linear SVC balanced	Cross-Validation	0.8164	0.0071	0.9138

	Quelle	Scoretyp	Modell	Experiment	Macro-F1	Macro-F1 Std	Weighted F1
6	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Full with geber category	0.8117	0.0147	0.9231
7	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Full model	0.8062	0.0209	0.922
8	Baseline Cross-Validation	Cross-Validation	SGD hinge balanced	Cross-Validation	0.8062	0.0209	0.922
9	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Text only	0.802	0.008	0.9256
10	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Ohne Name	0.7965	0.0177	0.9169
11	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Full with geber and art as text	0.7954	0.021	0.9228
12	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Ohne Anschrift	0.7918	0.0191	0.921
13	Baseline Cross-Validation	Cross-Validation	SGD log loss balanced	Cross-Validation	0.7793	0.008	0.8817
14	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Ohne Empfängeridentität	0.7664	0.0192	0.897
15	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Zweck + geber category	0.7525	0.0073	0.9054
16	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Zweck + geber text	0.7483	0.0135	0.9042
17	fastText Baseline	Interner Validierungssplit	fastText	Interner Validierungssplit	0.7435	-	0.9372
18	Baseline Cross-Validation	Cross-Validation	Complement Naive Bayes text only	Cross-Validation	0.6306	0.0041	0.8539
19	Ablation und Repräsentation	Cross-Validation	SGD hinge balanced	Zweck only	0.5994	0.0128	0.8304
20	Baseline Cross-Validation	Cross-Validation	Dummy Classifier	Cross-Validation	0.0103	0.0	0.0653
21	Gespeichertes Kontrollmodell	Gespeichertes Modell	logistic_regression_balanced__full_model	scikit-learn	-	-	-
22	Gespeichertes fastText-Modell	Gespeichertes Modell	best_fasttext_politikbereich	fastText	-	-	-
23	Gespeichertes fastText-Modell	Gespeichertes Modell	fasttext_politikbereich	fastText	-	-	-
24	Gespeichertes scikit-learn-Modell	Gespeichertes Modell	best_optuna_sgd_hinge	scikit-learn	-	-	-

Diese Übersicht fasst Validierungs-, Cross-Validation- und gespeicherte Modellkandidaten in einer gemeinsamen Struktur zusammen. Die Werte sind jedoch nicht identisch zu interpretieren: Cross-Validation- und Validierungswerte dienen der Modellauswahl, während die finale Bewertung erst auf dem separaten Testdatensatz erfolgt.

8.4. Hilfsfunktionen für die Testevaluation

Alle Modelle werden mit denselben Testdaten und denselben Metriken bewertet. Dadurch sind die Ergebnisse direkt vergleichbar. Für jedes Modell werden außerdem ein klassenbezogener Report und optional eine Konfusionsmatrix erzeugt.

► Code

8.5. Gespeicherte scikit-learn-Modelle evaluieren

Die scikit-learn-Modelle wurden als `joblib`-Dateien gespeichert. Dazu gehören aktuell das beste Optuna-Modell sowie gespeicherte Kontrollmodelle. Die Modelle enthalten ihre jeweilige Vorverarbeitung, daher können sie direkt auf dem Test-DataFrame angewendet werden.

► Code

Gefundene scikit-learn-Modelle: 2

- d:\toydev\schwarz-test\models\control_comparison\logistic_regression_balanced__full_model.joblib
- d:\toydev\schwarz-test\models\optuna\best_optuna_sgd_hinge.joblib

8.6. CatBoost-Modell evaluieren, falls vorhanden

CatBoost wird separat evaluiert, weil das Modell nicht als scikit-learn-`Pipeline`, sondern im nativen CatBoost-Format gespeichert wird. Für die Vorhersage werden dieselben Text-, Kategorie- und Zahlenmerkmale verwendet wie in der CatBoost-Baseline.

► Code

Kein gespeichertes CatBoost-Modell gefunden.

8.7. fastText-Modell evaluieren, falls vorhanden

fastText wird separat evaluiert, weil es kein scikit-learn-Objekt ist. Für die Vorhersage wird derselbe markierte Text erzeugt, der auch in der fastText- und BERT-Vorbereitung verwendet wurde. Falls das Paket `fasttext` in der aktuellen Umgebung nicht installiert ist, wird dieser Schritt übersprungen.

► Code

8.8. BERT-Modell evaluieren, falls vorhanden

Ein gespeichertes BERT-Modell wird nur evaluiert, wenn Modellordner, Tokenizer und Labelencoder vorhanden sind und die benötigten Pakete installiert sind. Dieser Schritt ist optional, weil BERT nicht in jeder Umgebung trainiert wurde.

► Code

Kein gespeichertes BERT-Modell gefunden.

8.9. Finale Testergebnisse vergleichen

Die folgende Tabelle enthält nur Ergebnisse auf dem finalen Testdatensatz. Das beste Modell wird primär anhand von `test_macro_f1` betrachtet. Zusätzlich sollten Weighted-F1, Balanced Accuracy und die klassenbezogenen Reports geprüft werden.

► Code

Gespeichert: `d:\toydev\schwarz-test\reports\final_evaluation\final_test_evaluation_results.csv`

	model_name	model_type	test_macro_f1	test_weighted_f1	test_balanced_accuracy	test_a
0	best_fasttext_politikbereich	fastText	0.807763	0.945531	0.790707	0.9459
1	best_optuna_sgd_hinge	scikit-learn	0.799919	0.947517	0.811271	0.9472
2	logistic_regression_balanced__full_model	scikit-learn	0.511007	0.672921	0.659705	0.6678

Bestes Modell auf dem Testdatensatz: `best_fasttext_politikbereich`
Test-Macro-F1: `0.8077631268236054`

Die finale Tabelle ist nach `test_macro_f1` sortiert und bewertet alle verfügbaren gespeicherten Modelle auf demselben zurückgehaltenen Testdatensatz. Diese Werte sind daher aussagekräftiger für die erwartete Generalisierungsleistung als die vorherigen Validierungs- oder Cross-Validation-Ergebnisse.

8.10. Klassenbezogenen Report des besten Modells anzeigen

Der aggregierte Score allein reicht bei ungleichen Klassen nicht aus. Deshalb wird für das beste Modell der Report pro Klasse angezeigt. Besonders relevant sind Klassen mit niedrigem Support oder sehr niedrigen F1-Werten.

► Code

	precision	recall	f1-score	support
Antidiskriminierung	0.924528	0.869822	0.896341	169.000000
Arbeit	0.980342	0.990391	0.985341	1561.000000
Bauen, Wohnen	1.000000	0.857143	0.923077	21.000000
Berlin-Image	0.000000	0.000000	0.000000	1.000000
Bildung	0.977307	0.958457	0.967790	674.000000
Bürgerschaftliches Engagement, Bürgerbeteiligung	0.718663	0.735043	0.726761	351.000000
Denkmalschutz	0.958333	0.867925	0.910891	53.000000
Europa	0.785714	0.523810	0.628571	21.000000
Familie	0.979424	0.944444	0.961616	252.000000
Finanzen	1.000000	1.000000	1.000000	4.000000
Forschung	0.933333	1.000000	0.965517	56.000000
Frauen	0.785714	0.687500	0.733333	48.000000
Gesundheit	0.924460	0.909735	0.917038	565.000000
Gleichstellung	0.873134	0.928571	0.900000	126.000000
Integration	0.871060	0.883721	0.877345	344.000000
Internationales	0.333333	0.200000	0.250000	5.000000
Jugend	0.930308	0.957465	0.943691	1199.000000
Justiz	0.978261	0.978261	0.978261	46.000000
Kirchen, Religions-, Weltanschauungsgemeinschaften	0.694444	0.568182	0.625000	44.000000
Kultur	0.876604	0.946695	0.910302	938.000000
Medien	0.500000	0.500000	0.500000	4.000000
Pflege	0.980392	0.909091	0.943396	110.000000
Sicherheit, Ordnung	1.000000	0.906250	0.950820	32.000000
Soziales	0.923218	0.882867	0.902592	572.000000
Sport	0.995847	0.992550	0.994196	1208.000000
Stadtentwicklung	0.857143	0.860294	0.858716	272.000000
Tierschutz	0.000000	0.000000	0.000000	2.000000
Umwelt	0.938095	0.856522	0.895455	230.000000
Verbraucherschutz	0.833333	0.750000	0.789474	40.000000
Verkehr	1.000000	0.986425	0.993166	221.000000
Wirtschaft	0.999559	0.997797	0.998677	2270.000000
Wissenschaft	1.000000	0.853659	0.921053	41.000000
accuracy	0.945906	0.945906	0.945906	0.945906
macro avg	0.829767	0.790707	0.807763	11480.000000

	precision	recall	f1-score	support
weighted avg	0.945962	0.945906	0.945531	11480.000000

Klassen mit den niedrigsten F1-Werten:


	politikbereich	precision	recall	f1-score	support
3	Berlin-Image	0.000000	0.000000	0.000000	1.0
26	Tierschutz	0.000000	0.000000	0.000000	2.0
15	Internationales	0.333333	0.200000	0.250000	5.0
20	Medien	0.500000	0.500000	0.500000	4.0
18	Kirchen, Religions-, Weltanschauungsgemeinscha...	0.694444	0.568182	0.625000	44.0
7	Europa	0.785714	0.523810	0.628571	21.0
5	Bürgerschaftliches Engagement, Bürgerbeteiligung	0.718663	0.735043	0.726761	351.0
11	Frauen	0.785714	0.687500	0.733333	48.0
28	Verbraucherschutz	0.833333	0.750000	0.789474	40.0
25	Stadtentwicklung	0.857143	0.860294	0.858716	272.0

Der klassenbezogene Report zeigt, ob gute Gesamtwerte auch für kleinere Politikbereiche gelten. Gerade bei seltenen Klassen können Precision, Recall und F1-Score stark schwanken. Diese Klassen sollten deshalb nicht nur über den Gesamtscore, sondern auch einzeln geprüft werden.

8.11. Konfusionsmatrix des besten Modells

Die Konfusionsmatrix zeigt, welche Politikbereiche das Modell typischerweise verwechselt. Bei vielen Klassen ist die Darstellung groß, aber für die finale Analyse und Präsentation hilfreich.

► Code



8.12. Grenzen der bisherigen Modellierung und Verbesserungsmöglichkeiten

Die finale Evaluation zeigt den aktuellen Stand der Modellierung, deckt aber noch nicht alle sinnvollen Modell- und Optimierungsstrategien ab. Aufgrund der begrenzten Bearbeitungszeit sowie der verfügbaren CPU- und GPU-Kapazität konnten einige weiterführende Experimente nicht vollständig umgesetzt werden.

Neben den bereits geprüften klassischen Modellen, fastText, BERT-Vorbereitungen und CatBoost wären weitere moderne Ansätze interessant gewesen. Besonders relevant wäre ein Vergleich mit **AutoGluon** **MultiModalPredictor**, da dieses Framework Text-, kategoriale und numerische Merkmale gemeinsam modellieren

kann. Zusätzlich wäre ein deutschsprachiges Transformer-Modell wie **ModernGBERT_134M** ein sinnvoller Kandidat gewesen, um zu prüfen, ob ein moderneres, kleineres German-BERT-Modell bessere Ergebnisse bei vertretbarer Laufzeit liefert.

Darüber hinaus wären neuronale Netze für die nicht-textuellen Merkmale interessant gewesen. Ein Feedforward Neural Network auf numerischen und kategorial kodierten Merkmalen könnte zeigen, ob Informationen wie **art**, **jahr**, **betrag** oder institutionelle Merkmale einen eigenständigen Beitrag zur Klassifikation leisten. Auch hybride Architekturen, die Textrepräsentationen mit strukturierten Merkmalen kombinieren, wären eine sinnvolle Erweiterung.

Eine vollständige Hyperparameteroptimierung wurde nicht für alle Modellkandidaten durchgeführt. Für einzelne schnelle Modelle wie **SGDClassifier** und fastText konnten erste Optuna-basierte Varianten geprüft werden. Für langsamere Modelle wie logistische Regression, CatBoost, BERT, neuronale Netze oder weitere Transformer-Modelle wäre jedoch eine breitere und systematischere Suche notwendig gewesen.

Insbesondere für neuronale Netze oder andere iterative Modelle hätte zusätzlich eine ressourcenschonende Tuning-Strategie wie Hyperband getestet werden können. Hyperband bzw. verwandte Pruning-Verfahren wie **HyperbandPruner** oder **SuccessiveHalvingPruner** in Optuna können schwache Trials früh abbrechen, sobald sich während des Trainings zeigt, dass sie wahrscheinlich keine konkurrenzfähige Leistung erreichen. Dadurch könnten bei begrenzter Rechenzeit mehr Hyperparameterkombinationen geprüft werden.

Ensemble-Strategien wurden ebenfalls noch nicht ausgeschöpft. Sinnvoll wären Kombinationen aus einem linearen TF-IDF-Modell, fastText, CatBoost, einem neuronalen Netz für strukturierte Merkmale und einem Transformer-Modell. Dabei könnten einfache Mehrheitsentscheidungen, gewichtete Soft-Voting-Ansätze oder Stacking-Verfahren getestet werden.

Ein weiterer Verbesserungsbereich betrifft die Robustheitsprüfung. Zusätzlich zur bisherigen stratifizierten Cross-Validation wäre eine Analyse sinnvoll, wie stabil die Modelle über einzelne Jahre, seltene Klassen und unterschiedliche Empfängergruppen hinweg sind. Auch eine detailliertere Fehleranalyse pro Politikbereich könnte zeigen, welche Klassen systematisch verwechselt werden.

Schließlich könnten die Feature-Experimente weiter ausgebaut werden. Für die stärksten Modellkandidaten wären weitere Varianten sinnvoll, zum Beispiel ohne adressbezogene Merkmale, mit stärker reduzierten Empfängerinformationen oder mit alternativen Textrepräsentationen. Dadurch ließe sich besser beurteilen, ob die Modelle tatsächlich inhaltliche Muster des Förderzwecks lernen oder teilweise stark von institutionellen Identifikationsmerkmalen abhängen.

Zusammenfassend ist das aktuelle Ergebnis als belastbare erste Modellierungsbasis zu verstehen. Für eine produktionsnahe Lösung sollten zusätzliche Modellfamilien, neuronale Netze für strukturierte Merkmale, breitere Hyperparameteroptimierung mit Pruning, Ensemble-Ansätze, Robustheitsanalysen und eine vertiefte Fehleranalyse ergänzt werden.

Die finale Evaluation zeigt den aktuellen Stand der Modellierung, deckt aber noch nicht alle sinnvollen Modell- und Optimierungsstrategien ab. Aufgrund der begrenzten Bearbeitungszeit sowie der verfügbaren CPU- und GPU-Kapazität konnten einige weiterführende Experimente nicht vollständig umgesetzt werden.

Neben den bereits geprüften klassischen Modellen, fastText, BERT-Vorbereitungen und CatBoost wären weitere moderne Ansätze interessant gewesen. Besonders relevant wäre ein Vergleich mit **AutoGluon MultiModalPredictor**, da dieses Framework Text-, kategoriale und numerische Merkmale gemeinsam modellieren kann. Zusätzlich wäre ein deutschsprachiges Transformer-Modell wie **ModernGBERT_134M** ein sinnvoller Kandidat gewesen, um zu prüfen, ob ein moderneres, kleineres German-BERT-Modell bessere Ergebnisse bei vertretbarer Laufzeit liefert.

Darüber hinaus wären neuronale Netze für die nicht-textuellen Merkmale interessant gewesen. Ein Feedforward Neural Network auf numerischen und kategorial kodierten Merkmalen könnte zeigen, ob Informationen wie **art**, **jahr**, **betrag** oder institutionelle Merkmale einen eigenständigen Beitrag zur Klassifikation leisten. Auch hybride Architekturen, die Textrepräsentationen mit strukturierten Merkmalen kombinieren, wären eine sinnvolle Erweiterung.

Eine vollständige Hyperparameteroptimierung wurde nicht für alle Modellkandidaten durchgeführt. Für einzelne schnelle Modelle wie **SGDClassifier** und fastText konnten erste Optuna-basierte Varianten geprüft werden. Für langsamere Modelle wie logistische Regression, CatBoost, BERT, neuronale Netze oder weitere Transformer-Modelle wäre jedoch eine breitere und systematischere Suche notwendig gewesen.

Insbesondere für neuronale Netze oder andere iterative Modelle hätte zusätzlich eine ressourcenschonende Tuning-Strategie wie Hyperband getestet werden können. Hyperband bzw. verwandte Pruning-Verfahren wie **HyperbandPruner** oder **SuccessiveHalvingPruner** in Optuna können schwache Trials früh abbrechen, sobald sich während des Trainings zeigt, dass sie wahrscheinlich keine konkurrenzfähige Leistung erreichen. Dadurch könnten bei begrenzter Rechenzeit mehr Hyperparameterkombinationen geprüft werden.

Ensemble-Strategien wurden ebenfalls noch nicht ausgeschöpft. Sinnvoll wären Kombinationen aus einem linearen TF-IDF-Modell, fastText, CatBoost, einem neuronalen Netz für strukturierte Merkmale und einem Transformer-Modell. Dabei könnten einfache Mehrheitsentscheidungen, gewichtete Soft-Voting-Ansätze oder Stacking-Verfahren getestet werden.

Ein weiterer Verbesserungsbereich betrifft die Robustheitsprüfung. Zusätzlich zur bisherigen stratifizierten Cross-Validation wäre eine Analyse sinnvoll, wie stabil die Modelle über einzelne Jahre, seltene Klassen und unterschiedliche Empfängergruppen hinweg sind. Auch eine detailliertere Fehleranalyse pro Politikbereich könnte zeigen, welche Klassen systematisch verwechselt werden.

Schließlich könnten die Feature-Experimente weiter ausgebaut werden. Für die stärksten Modellkandidaten wären weitere Varianten sinnvoll, zum Beispiel ohne adressbezogene Merkmale, mit stärker reduzierten Empfängerinformationen oder mit alternativen Textrepräsentationen. Dadurch ließe sich besser beurteilen, ob die Modelle tatsächlich inhaltliche Muster des Förderzwecks lernen oder teilweise stark von institutionellen Identifikationsmerkmalen abhängen.

Zusammenfassend ist das aktuelle Ergebnis als belastbare erste Modellierungsbasis zu verstehen. Für eine produktionsnahe Lösung sollten zusätzliche Modellfamilien, neuronale Netze für strukturierte Merkmale, breitere Hyperparameteroptimierung mit Pruning, Ensemble-Ansätze, Robustheitsanalysen und eine vertiefte Fehleranalyse ergänzt werden.

